

Bitácora del escalado progresivo

Registro cronológico de las etapas 0-2 del plan (docs/plan_escalado_progresivo.md): qué se corrió, con qué configuración, qué dio y qué se decidió en cada paso. Fecha de inicio: 2026-08-09.

Objetivo rector: **copiar la dinámica** (NRMSE de rollout open-loop sobre estímulos de test). Métricas secundarias: R^2 de la corrección contra el Δf verdadero y error de parámetros.

Preparación

Infraestructura nueva:

- `scripts/esc_gen_datasets.py` — genera los datasets con UNA perturbación: `refrac1.npz` (solo refractariedad, $r=0.10$) y `act1.npz` (solo actuador, $\tau=1.0$ ms, $\text{sat}=3.0$). Mismos valores que `default_uncertainty(eps=1)` para que todo sea comparable con los experimentos F.
- `scripts/esc_eval.py` — evaluación unificada: para cualquier modelo reporta NRMSE de rollout (test), R^2 de la corrección implícita contra el Δf verdadero, y error de parámetros.

Decisiones de diseño:

- La corrección "implícita" se mide como `f_modelo - f_WC( $\hat{\theta}$ )` con los $\hat{\theta}$ aprendidos: así la misma métrica sirve para la red aditiva (donde coincide con `g`), para la corrección estructurada y para los modelos con memoria.
- Los datasets aislados usan el mismo catálogo de 20 escenarios (13 train / 7 test) y el mismo integrador que los `eps*.npz` existentes.

(las corridas se registran abajo a medida que terminan)

Datasets generados (`scripts/esc_gen_datasets.py` , 20 escenarios cada uno, 13 train / 7 test, sin ruido de observación):

- `refrac1.npz` — $|\Delta f|$ va de ~ 0.0001 (estímulos suaves) a 0.021 (`prbs_1`): la refractariedad solo muerde donde la actividad es alta, como se esperaba.
- `act1.npz` — $|\Delta f|$ más parejo y más grande (hasta 0.035 en `chirp`): el retardo del actuador deforma siempre que el estímulo se mueve.

Etapla 0 — Referencia limpia

White-box de F2 (entrenado sobre `eps0.npz`) evaluado con el pipeline nuevo:

métrica	valor
NRMSE rollout test	2.04% (I 2.03 / E 2.04)
error medio de parámetros	1.05%

Coincide con lo documentado: **el piso es ~2%**. El único escenario flojo es `box_a1.2` (10.8%), el escalón grande — ya era el caso duro antes. R^2 contra Δf da NaN porque en `eps0` el Δf verdadero es idénticamente cero (correcto).

Etapas 1 — Solo refractariedad

Corridas lanzadas (todas sobre `refrac1.npz`, 1500 épocas + L-BFGS):

tag	variante	ventana	qué contesta
<code>e1_wb</code>	white-box	100 (5 ms)	¿cuánto daña la refractariedad sola?
<code>e1_B_w100</code>	gray-box B <code>g(I,E)</code>	100	la corrección ciega, config de siempre
<code>e1_B_w200</code>	gray-box B	200 (10 ms)	¿ayuda entrenar con ventanas más largas?
<code>e1_B_w400</code>	gray-box B	400 (20 ms)	ídem, más largo
<code>e1_S</code>	estructural <code>(1-r·x)·S(u)</code>	100	1b: la forma exacta, ¿clava r?

Primer resultado — `e1_wb` (white-box, 22 min):

métrica	valor	contra referencia
NRMSE rollout test	5.93%	piso limpio 2.04%; con las DOS perturbaciones era 14.0%
R^2 corrección implícita	-0.27	(whitebox: no hay corrección, mide el sesgo de $\hat{\theta}$ deformados)
error medio de parámetros	11.5%	con las dos perturbaciones era 59.5%

Lectura: **la refractariedad sola es un problema mucho más benigno** que el par completo — el white-box ya la compensa bastante deformando poco los parámetros (11.5%). El margen de mejora para el gray-box en NRMSE es 5.93% → ~2% (piso).

`e1_S` (estructural, 140 min — lenta por competencia de CPU): dio **idéntica al white-box** (NRMSE 5.92%, mismos parámetros). El checkpoint muestra por qué: aprendió `r_i = r_e = 0.0` exactos y saturación → ∞ , o sea colapsó a WC puro en vez de encontrar el `r = 0.10` verdadero. Causa probable: `r` se parametriza `clamp(raw, 0, 2)`; si al principio el gradiente lo empuja por debajo de 0 (mientras los θ todavía están lejos), queda pegado al borde **sin gradiente** y nunca sale. Es una falla de optimización, no estructural — la forma acá es exacta. **Acción:** relanzar `e1_S2` con `r` inicial 0.05 y warm-start de θ desde el white-box.

Barrido de ventana del gray-box B (terminado):

tag	ventana	NRMSE test	I / E	R^2 g vs Δf	err. param	wll
<code>e1_wb</code>	100	5.93%	5.91 / 5.96	-0.27	11.5%	72%
<code>e1_B_w100</code>	100 (5 ms)	2.99%	3.53 / 2.45	0.02	21.3%	59%
<code>e1_B_w200</code>	200 (10 ms)	3.31%	3.36 / 3.26	-0.39	24.6%	64%
<code>e1_B_w400</code>	400 (20 ms)	2.84%	2.82 / 2.85	-0.49	25.6%	61%

Lecturas:

1. **La corrección ciega funciona para copiar la dinámica:** baja de 5.93% a ~2.9%, o sea recupera el ~**75% del hueco** hasta el piso limpio de 2.04%. Por escenario (e1_B_w100): prbs_1 0.9%, poisson_1 0.9%, chirp 1.0%, box_a1.2 9.8% (el escalón grande sigue siendo el caso duro, como en el piso limpio, 10.8%).
2. **La ventana casi no importa** en NRMSE (2.84–3.31%, dentro del ruido entre seeds). La sospecha de que entrenar con 5 ms era el cuello de botella **no se confirmó** — al menos con refractariedad sola.
3. **Pero $R^2 \approx 0$ en todas:** la red copia la trayectoria sin aprender la física. El backbone deforma θ (error sube de 11.5% a 21–26%, con wII ~60%) y la red compensa el resto. Es la ambigüedad θ/g de F4b otra vez: predecir bien $\neq$ entender. Para el objetivo actual (copiar la dinámica) esto es aceptable; para cancelar en lazo cerrado no.
4. Costo: las corridas B tardaron ~25 h cada una — no por sí mismas (una sola tarda ~25 min) sino por correr 4 carriles $\times$ 4 hilos sobre 8 cores con ventanas largas. Nota para el futuro: **no más de 2 corridas en paralelo**.

Criterio de éxito de la etapa 1 ($\text{NRMSE} \leq \sim 4\%$ y $R^2 > 0.9$): la mitad. NRMSE  (2.8–3.0%), R^2  (≈ 0). El smoke test de e1_S2 (estructural con r inicial 0.05 y warm-start desde el white-box, solo 2 épocas + L-BFGS) dio **NRMSE 1.48% y R^2 0.965** — la forma exacta bien inicializada cumple las dos.

e1_S2 completa (13 min):

métrica	valor
NRMSE rollout test	1.70% (I 1.68 / E 1.71) — por debajo del piso limpio 2.04%
R^2 corrección vs Δf	0.964 (techo teórico 0.97)
error medio de parámetros	2.42% (wII 16.5%, el resto $< 1.5\%$)
refractariedad aprendida	r_e = 0.102 (verdadero 0.10); r_i = 0.0 (verdadero 0.10)

r_i no se identificó: el canal I casi no siente la refractariedad ($|\Delta f_I|$ es $\sim 7\times$ menor que $|\Delta f_E|$), así que no hay señal para moverlo y quedó en el borde. No afecta la predicción. Por escenario: todos $< 1\%$ salvo box_a1.2 (8.8%).

Conclusión etapa 1: cumplida. Dos caminos válidos según el objetivo: - *copiar la dinámica sin saber la forma*: gray-box B ciego, ~2.9%, $R^2 \approx 0$; - *copiar Y entender*: estructural con warm-start, 1.7%, R^2 0.96, r exacto.

Y una lección de método que se repitió en las dos etapas: **las correcciones con forma física fallan por inicialización, no por forma** — arrancar en el borde de un clamp mata el gradiente. Warm-start de θ desde el white-box + parámetro físico inicial > 0 lo arregla.

Etapla 2 — Solo actuador

Corridas lanzadas (todas sobre act1.npz):

tag	variante	ventana	qué contesta
e2_wb	white-box	100	¿cuánto daña el actuador solo?

tag	variante	ventana	qué contesta
e2_B	gray-box B	100	control negativo: $g(I, E)$ no debería poder
e2_lag	lag estructural ($\hat{t}$, sat aprendibles)	100	2a: la forma física, ¿lo clava?
e2_lat_w100	latente (z de dim 2 aprendido)	100	2b: memoria genérica
e2_lat_w400	latente	400	2b con ventana larga (z arranca en 0 por ventana: necesita tiempo para cargarse)

Código nuevo: `src/neural_ode/memory.py` — `LagGrayBox` (estado aumentado $[I, E, \hat{P}, \hat{Q}]$ con $d\hat{P}/dt = (P - \hat{P})/\hat{t}$ y saturación aprendible) y `LatentGrayBox` ($\dot{z} = h_\psi(x, z, P, Q)$, corrección $g_\phi(x, z)$, ambas redes con salida inicial 0). Entrenador `fit_aug` con multiple shooting; el estado oculto se inicializa por ventana (filtro asentado en el comando `/ z=0`) y la loss solo mira (I,E).

Resultados (todas terminadas):

tag	variante	NRMSE test	I / E	R ² vs Δf	err. param	extras aprendidos
e2_wb	white-box	15.23%	13.96 / 16.51	-0.01	30.7%	—
e2_B	gray-box $g(I, E)$	15.40%	15.51 / 15.29	-1.88	34.4%	—
e2_lag	lag estructural	12.16%	12.43 / 11.89	0.65	39.2%	$\hat{t}=0.56$ (real 1.0), $\text{sat} \rightarrow \infty$ (real 3.0)
e2_lat_w100	latente $z \in \mathbb{R}^2$	14.92%	14.91 / 14.93	-0.51	38.9%	—
e2_lat_w400	latente, $W=400$	13.28%	17.14 / 9.42	-3.55	52.6%	—

Lecturas:

1. **El actuador solo daña más que la refractariedad sola** (white-box 15.2% contra 5.9%), y de hecho tanto como las dos juntas (14.0%). Confirma que el retardo es lo que domina el problema original.
2. **$g(I, E)$ no puede, como se predijo** (15.4%, $R^2 -1.9$): control negativo correcto.
3. **La forma física con memoria es la única que aprende algo real:** R^2 0.65 —el mejor de todo el escalado hasta acá— y baja el NRMSE a 12.2%. Pero está lejos de clavarlo, y el checkpoint dice por qué: **$\hat{t}$ se quedó en 0.56 (la mitad del real) y la saturación se apagó** (α pegado al borde inferior del clamp, mismo defecto que `e1_s`).
4. **El latente genérico no ayuda** (13.3-14.9%) y arruina los parámetros (52% con $W=400$). Con z arrancando en 0 en cada ventana de 5 ms, la memoria no llega a cargarse; con $W=400$ mejora E pero rompe I. Necesita más trabajo (inicialización de z , o encoder desde la historia) — no es prioridad.

Diagnóstico del e2_lag — dos defectos de entrenamiento, no de modelo:

- *Transitorio falso por ventana.* En multiple shooting cada ventana arrancaba con $\hat{P} = P(t_0)$ (filtro "asentado"). Pero el filtro real nunca está asentado cuando el comando se mueve: la ventana arranca con un salto de $\hat{P}$ que no existe en la planta, y el modelo lo

minimiza achicando $\hat{t}$. Como el estado del actuador **depende solo del comando (conocido entero) y de $\hat{t}$** , se puede computar exacto filtrando toda la trayectoria — sin suponer nada. Implementado: `LagGrayBox.filtered_inputs` (solución exacta del ZOH, diferenciable en $\hat{t}$), usado por `fit_aug` para el estado inicial de cada ventana y por `esc_eval` en el R^2 teacher-forced.

- α en el borde muerto. Arrancaba en 0.01 y cayó al clamp 1e-3, donde no hay gradiente. Ahora arranca en 0.1.

e2_lag2 completa (28 min):

métrica	e2_lag (antes)	e2_lag2 (corregida)
NRMSE rollout test	12.16%	2.96% (I 3.01 / E 2.91)
R^2 corrección vs Δf	0.65	0.942
error medio de parámetros	39.2%	5.11% (todos < 10%)
$\hat{t}$ aprendido (real 1.0)	0.56	0.984
saturación (real 3.0)	∞	∞ (no identificada)

Con el estado inicial exacto por ventana el modelo con memoria física clava el actuador: de 15.2% (white-box) a 2.96%, con $\hat{t}$ dentro del 2%. La saturación volvió a apagarse: α cayó al borde del clamp aun arrancando en 0.1. Es consistente con lo medido en F1 (la saturación aporta ~16% de la deformación del actuador, el retardo el resto) — con $\hat{t}$ bien puesto queda muy poca señal para α , y la que queda la absorben los θ . No impide llegar al 3%. Por escenario: todo < 3% salvo `box_a1.2` (12.8%), el escalón grande, que es donde la saturación sí muerde — coherente.

Conclusión etapa 2: cumplida para 2a (criterio $\leq \sim 4\%$: 2.96% ). 2b (latente genérico) quedó en 13.3% y necesita otro diseño (no se insistió: no era el cuello de botella).

Cierre de la bitácora

Las tres etapas quedaron con receta validada. El informe consolidado, con la tabla comparativa y la recomendación para las etapas 3–4, está en `docs/resultados_escalado.md`.