

M1 — Repaso: cálculo y álgebra lineal para el proyecto

Un puente desde tu base hacia el Jacobiano, el Hessiano y la matriz de Fisher

Proyecto Wilson–Cowan — Iniciación a la I+D ITBA

12 de julio de 2026

Índice

Antes de empezar	1
1. Derivadas parciales, gradiente y regla de la cadena	1
2. Jacobiano y Hessiano	2
3. Matrices: producto, transpuesta, simetría, rango, definida positiva	2
4. Autovalores y autovectores	3
5. Formas cuadráticas y su geometría	3
6. Normas, ortogonalidad y número de condición	4
7. Serie de Taylor de segundo orden	5
Síntesis	6

Antes de empezar

Este documento es un *puente*: no reexplica qué es una derivada ni para qué sirve una matriz, sino que refresca las herramientas exactas que vamos a necesitar más adelante en el proyecto. Todo lo que aparece acá reaparece en dos lugares concretos:

- En **M5** vamos a definir la *sensibilidad* de la salida del modelo Wilson–Cowan (WC) respecto de sus parámetros, $J = \partial \mathbf{y} / \partial \boldsymbol{\theta}$. Eso es un Jacobiano.
- En **M6** vamos a diagnosticar *qué parámetros se pueden identificar* usando la matriz de información de Fisher (FIM), sus autovalores y su número de condición. Ahí aparece el famoso “valle plano” del error, que no es más que una forma cuadrática muy alargada.

El objetivo del proyecto es identificar los 10 parámetros de WC a partir de datos ruidosos y diagnosticar por qué w_{II} (la autoinhibición) es el cuello de botella. Toda la maquinaria de este repaso apunta a eso. Cerramos cada sección con una frase “en el proyecto esto reaparece en...” para que no pierdas de vista el hilo.

1. Derivadas parciales, gradiente y regla de la cadena

Definición 1 (Derivada parcial y gradiente). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función escalar de varias variables, $f(\boldsymbol{\theta})$ con $\boldsymbol{\theta} = (\theta_1, \dots, \theta_n)$. La **derivada parcial** $\partial f / \partial \theta_j$ mide cuánto cambia f si

movés solo θ_j dejando las demás fijas. El **gradiente** las junta a todas en un vector:

$$\nabla f(\boldsymbol{\theta}) = \left(\frac{\partial f}{\partial \theta_1}, \dots, \frac{\partial f}{\partial \theta_n} \right)^\top.$$

Intuición. El gradiente apunta en la dirección de *máximo crecimiento* de f , y su opuesto $-\nabla f$ en la de máximo descenso. Su norma dice qué tan empinada es la subida. Si $\nabla f = \mathbf{0}$, estás en un punto crítico (mínimo, máximo o silla).

Por qué en este proyecto. Cuando entrenamos el modelo (Neural ODE o PINN) minimizamos un error $L(\boldsymbol{\theta})$ entre la salida simulada $\mathbf{y}(t; \boldsymbol{\theta}) = E(t) - I(t)$ y los datos. El optimizador (Adam, gradiente descendente) se mueve siguiendo $-\nabla_{\boldsymbol{\theta}} L$. Cada componente $\partial L / \partial \theta_j$ nos dice cuánto “escucha” el error a mover, por ejemplo, w_{IE} o w_{II} .

Regla de la cadena. Es la herramienta que hace posible todo esto. Si L depende de $\boldsymbol{\theta}$ a través de una composición de funciones (la sigmoidea S_a , el integrador de la EDO, la resta $E - I$), la derivada se propaga multiplicando eslabones:

$$\frac{\partial L}{\partial \theta_j} = \sum_k \frac{\partial L}{\partial u_k} \frac{\partial u_k}{\partial \theta_j}.$$

La *diferenciación automática* (backprop) no es otra cosa que aplicar esta regla de forma sistemática a lo largo del grafo de cómputo.

Observación 1. En WC, un parámetro entra “adentro” de la sigmoidea $S_a(u) = 1/(1 + e^{-au})$. Para derivar respecto de él necesitas $S'_a(u) = a S_a(u) (1 - S_a(u))$ y después encadenar. Guardá esta fórmula: aparece en cada sensibilidad.

En el proyecto esto reaparece en: P4 (implementación de `neural_ode`) y M5, donde el gradiente y la regla de la cadena son el motor del entrenamiento y del cálculo de sensibilidades.

2. Jacobiano y Hessiano

Definición 2 (Jacobiano). Sea $\mathbf{F} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ una función vectorial, $\mathbf{F}(\boldsymbol{\theta}) = (F_1, \dots, F_m)$. Su **Jacobiano** es la matriz $m \times n$ de todas las derivadas parciales:

$$J = \frac{\partial \mathbf{F}}{\partial \boldsymbol{\theta}}, \quad J_{ij} = \frac{\partial F_i}{\partial \theta_j}.$$

Intuición. El Jacobiano es la *mejor aproximación lineal* de $\mathbf{F}$ cerca de un punto: $\mathbf{F}(\boldsymbol{\theta} + \Delta \boldsymbol{\theta}) \approx \mathbf{F}(\boldsymbol{\theta}) + J \Delta \boldsymbol{\theta}$. Cada fila es el gradiente de una componente. Si $m = 1$, el Jacobiano es (la transpuesta de) el gradiente.

Por qué en este proyecto. La **sensibilidad** del proyecto es exactamente un Jacobiano. Apilamos la salida observada $y(t) = E(t) - I(t)$ en muchos instantes $t_1, \dots, t_m$ para formar el vector $\mathbf{y} \in \mathbb{R}^m$, y derivamos respecto de los 10 parámetros $\boldsymbol{\theta}$:

$$J = \frac{\partial \mathbf{y}}{\partial \boldsymbol{\theta}} \in \mathbb{R}^{m \times 10}.$$

La columna j dice cómo se deforma toda la trayectoria si perturbás el parámetro j . Si dos columnas son casi paralelas (por ejemplo las de w_{II} y otro peso), los datos “no pueden distinguir” esos parámetros: ese es el germen del problema de identificabilidad.

Definición 3 (Hessiano). Para $f : \mathbb{R}^n \rightarrow \mathbb{R}$ escalar, el **Hessiano** es la matriz $n \times n$ de segundas derivadas:

$$H = \nabla^2 f, \quad H_{ij} = \frac{\partial^2 f}{\partial \theta_i \partial \theta_j}.$$

Bajo condiciones de regularidad es simétrico ($H_{ij} = H_{ji}$, teorema de Schwarz).

Intuición. Si el gradiente es la “pendiente”, el Hessiano es la *curvatura*. Te dice cómo se curva la superficie del error alrededor de un punto: hacia dónde es un valle angosto (mucha curvatura) y hacia dónde es un valle plano (poca curvatura).

Por qué en este proyecto. Cerca del óptimo, la matriz de información de Fisher se aproxima como $FIM \approx J^\top J$ (y coincide, salvo escala del ruido, con el Hessiano del error). Los parámetros con *poca curvatura* son los mal identificados: podés moverlos bastante sin que el error suba. Adelantamos ya el resultado: w_{II} vive en la dirección de menor curvatura de la FIM, y por eso es el difícil de recuperar.

En el proyecto esto reaparece en: M5 (Jacobiano = sensibilidad) y M6 (Hessiano/FIM = curvatura del error = identificabilidad).

3. Matrices: producto, transpuesta, simetría, rango, definida positiva

Repasamos las propiedades que vamos a usar como ladrillos.

- **Producto** AB : componer transformaciones lineales. Recordá que no conmuta ($AB \neq BA$ en general).
- **Transpuesta** $A^\top$: refleja filas por columnas, $(A^\top)_{ij} = A_{ji}$. Cumple $(AB)^\top = B^\top A^\top$. En el proyecto casi todo pasa por $J^\top J$.
- **Simetría**: A es simétrica si $A = A^\top$. El Hessiano y la FIM lo son. Las matrices simétricas tienen propiedades muy cómodas (autovalores reales, autovectores ortogonales; ver Sección 4).
- **Rango**: número de columnas (o filas) linealmente independientes. Es la “dimensión efectiva” de la información que aporta la matriz. Si J tiene rango menor que 10, hay direcciones de parámetros que los datos *no ven*: identificabilidad estructural perdida.

Definición 4 (Matriz simétrica definida positiva (SDP)). *Una matriz simétrica A es **definida positiva** si $\mathbf{v}^\top A \mathbf{v} > 0$ para todo $\mathbf{v} \neq \mathbf{0}$; es **semidefinida positiva** si vale ≥ 0 . Equivale a que todos sus autovalores sean > 0 (≥ 0).*

Intuición. “Definida positiva” significa que la forma cuadrática asociada $\mathbf{v}^\top A \mathbf{v}$ es un cuenco que abre hacia arriba en todas las direcciones: hay un mínimo bien definido. Si es solo semidefinida, aparecen direcciones planas (autovalor 0).

Por qué en este proyecto. La FIM $\approx J^\top J$ es *siempre* semidefinida positiva por construcción. Que sea estrictamente definida positiva es justamente la condición de que *todos* los parámetros se puedan identificar localmente. Cuando la FIM tiene un autovalor casi nulo, estamos en el caso “semidefinida en la práctica”: la dirección de w_{II} .

En el proyecto esto reaparece en: M6, donde estudiamos la FIM ($J^\top J$, simétrica y semidefinida positiva) y su rango efectivo.

4. Autovalores y autovectores

Definición 5 (Autovalor y autovector). *Un vector $\mathbf{v} \neq \mathbf{0}$ es **autovector** de A con **autovalor** λ si*

$$A \mathbf{v} = \lambda \mathbf{v}.$$

Es decir, A actúa sobre esa dirección solo estirándola (o encogiéndola) por el factor λ , sin rotarla.

Intuición geométrica. Una matriz, en general, rota y estira el espacio. Los autovectores son las direcciones “especiales” que *no rotan*: solo se escalan. Para una matriz simétrica (nuestro caso: Hessiano, FIM), los autovectores son ortogonales entre sí y forman ejes naturales del problema. Los autovalores dicen cuánto se estira a lo largo de cada eje.

Por qué en este proyecto. Diagonalizar la FIM nos da sus ejes propios: cada autovector es una *combinación de parámetros* y su autovalor mide cuánta información tenemos sobre esa combinación. Autovalor grande = combinación bien determinada; autovalor chico = combinación indeterminada (valle plano). El diagnóstico Fisher+SVD del proyecto se apoya enteramente en leer estos autovalores/autovectores para señalar a w_{II} .

En el proyecto esto reaparece en: M6 (autovalores de la FIM = información por dirección; el autovector del menor autovalor apunta a w_{II}).

5. Formas cuadráticas y su geometría

Definición 6 (Forma cuadrática). *Dada una matriz simétrica A , la **forma cuadrática** asociada es*

$$q(\mathbf{v}) = \mathbf{v}^\top A \mathbf{v} = \sum_{i,j} A_{ij} v_i v_j.$$

Intuición geométrica. El conjunto de nivel $\mathbf{v}^\top A \mathbf{v} = c$ (con A definida positiva) es un **elipsoide**. Sus ejes apuntan en la dirección de los autovectores de A , y su longitud es proporcional a $1/\sqrt{\lambda_i}$. Autovalor grande $\Rightarrow$ eje corto (dirección “dura”, el cuenco sube rápido); autovalor chico $\Rightarrow$ eje largo (dirección “blanda”, el cuenco casi no sube). La Figura 1 muestra cómo una matriz convierte el círculo unitario en una elipse, que es la lectura visual de esta idea.




Figura 1: Una matriz transforma el círculo unitario en una elipse: los ejes de la elipse son las direcciones propias (vectores singulares) y sus longitudes son los valores singulares. Una elipse muy alargada corresponde a una forma cuadrática mal condicionada, con una dirección “dura” y una “blanda”. Esta es la geometría del “valle plano” del error. (figura del proyecto)

Por qué en este proyecto. Cerca del óptimo, el error se comporta como una forma cuadrática cuya matriz es el Hessiano ($\approx$ FIM). Entonces las curvas de nivel del error son elipsoides. Si un eje es larguísimo (autovalor casi nulo), tenemos el **valle plano**: podés recorrer esa dirección sin que el error cambie. Esa dirección larga es, en nuestro modelo, la que involucra a w_{II} : mover w_{II} casi no encarece el ajuste, y por eso los datos no lo fijan bien.

En el proyecto esto reaparece en: M6, donde “valle plano” = elipsoide de error con un eje muy largo = autovalor chico de la FIM.

6. Normas, ortogonalidad y número de condición

Definición 7 (Normas). La **norma euclídea** de un vector es $\|\mathbf{v}\|_2 = \sqrt{\mathbf{v}^\top \mathbf{v}}$. Para matrices, la **norma espectral** $\|A\|_2$ es el mayor valor singular de A (cuánto puede estirar como máximo a un vector unitario).

Ortogonalidad. Dos vectores son ortogonales si $\mathbf{u}^\top \mathbf{v} = 0$. Una matriz Q es **ortogonal** si $Q^\top Q = I$: representa una rotación/reflexión pura (no cambia longitudes ni ángulos). Los autovectores de una matriz simétrica se pueden elegir ortonormales, y esa base ortogonal es la que “endereza” la geometría del problema.

Definición 8 (Número de condición). Para una matriz A con valores singulares $\sigma_{\max} \geq \dots \geq \sigma_{\min}$, el **número de condición** es

$$\kappa(A) = \frac{\sigma_{\max}}{\sigma_{\min}}.$$

Si A es simétrica definida positiva, equivale a $\lambda_{\max}/\lambda_{\min}$.

Intuición. κ mide qué tan “estirado” es el elipsoide: $\kappa = 1$ es una esfera perfecta (bien condicionado); κ enorme es una elipse casi degenerada (mal condicionado). Un problema mal condicionado es sensible al ruido y difícil de optimizar: el descenso por gradiente rebota de pared a pared del valle en vez de avanzar hacia el fondo, como muestra la Figura 2.




Figura 2: Descenso por gradiente en un valle mal condicionado (número de condición κ grande): las curvas de nivel forman una elipse alargada y el gradiente zigzaguea entre las paredes en lugar de ir directo al mínimo. Cuanto mayor es κ , más lento y ruidoso el ajuste. (figura del proyecto)

Por qué en este proyecto. El número de condición de la FIM es la métrica de identificabilidad del proyecto: un κ enorme dice que hay una dirección de parámetros casi invisible para los datos. El diseño óptimo de experimentos (OED) busca justamente estímulos $P(t), Q(t)$ que bajen κ de la FIM, redondeando el elipsoide para que w_{II} deje de ser un valle plano.

En el proyecto esto reaparece en: M6 y en el OED (elegir el estímulo que minimiza κ de la FIM); también explica por qué el entrenamiento sufre cuando el problema está mal condicionado.

7. Serie de Taylor de segundo orden

Definición 9 (Aproximación cuadrática). *Alrededor de un punto θ_0 , una función escalar suave se aproxima como*

$$f(\theta) \approx f(\theta_0) + \nabla f(\theta_0)^\top (\theta - \theta_0) + \frac{1}{2}(\theta - \theta_0)^\top H(\theta_0) (\theta - \theta_0),$$

con H el Hessiano evaluado en θ_0 .

Intuición. Es la generalización a varias variables de la parábola que aproxima una curva. El término lineal usa el gradiente; el término cuadrático usa el Hessiano y fija la *forma* de la superficie.

Por qué en este proyecto. Este es el broche que une todo lo anterior. En el óptimo del ajuste, θ^* , el gradiente se anula ($\nabla L(\theta^*) = \mathbf{0}$), así que el término lineal desaparece y queda

$$L(\theta) \approx L(\theta^*) + \frac{1}{2}(\theta - \theta^*)^\top H(\theta^*) (\theta - \theta^*).$$

El error, cerca del óptimo, es *exactamente* una forma cuadrática cuya matriz es el Hessiano ($\approx$ FIM). Entonces:

- las curvas de nivel del error son elipsoides (Sección 5);
- los ejes son los autovectores de H y sus longitudes van como $1/\sqrt{\lambda_i}$ (Sección 4);
- un autovalor chico = eje largo = valle plano = parámetro mal identificado (w_{II}).

Todo el diagnóstico de identificabilidad del proyecto vive en este único desarrollo de Taylor de segundo orden.

En el proyecto esto reaparece en: M6, como la justificación formal de por qué la FIM/Hessiano describe la incertidumbre de los parámetros y por qué w_{II} cae en el valle plano.

Síntesis

El hilo conductor es corto: el **gradiente** entrena, el **Jacobiano** $J = \partial \mathbf{y} / \partial \theta$ es la sensibilidad (M5), y el **Hessiano**/FIM $\approx J^\top J$ describe la curvatura del error (M6). Diagonalizándolo obtenemos autovalores (información por dirección) y su cociente extremo, el **número de condición** κ . Un κ grande significa un elipsoide de error muy alargado — el “valle plano” — y ahí es donde w_{II} se vuelve inidentificable. El desarrollo de Taylor de segundo orden es lo que conecta “error” con “forma cuadrática” y cierra el argumento.

Referencias

- [1] G. Strang, *Linear Algebra and Its Applications*, Harcourt Brace Jovanovich, 3.^a ed., 1988.
- [2] G. H. Golub y C. F. Van Loan, *Matrix Computations*, Johns Hopkins University Press, 4.^a ed., 2013.