

M6 — Identificabilidad: sensibilidad, SVD, Fisher, Cramér–Rao y OED

Una sola matriz, $\mathbf{J} = \partial \mathbf{y} / \partial \boldsymbol{\theta}$, y todo lo que se lee en ella

Proyecto Wilson–Cowan — Iniciación a la I+D ITBA

12 de julio de 2026

Índice

1. El problema inverso y la matriz de sensibilidad	1
2. SVD de la sensibilidad	2
3. Matriz de información de Fisher (FIM)	3
4. Cota de Cramér–Rao: la incertidumbre correcta	4
5. Identificabilidad estructural vs. práctica	5
6. Remedios: qué fijar, cómo regularizar, qué estímulo usar	6
6.1. Selección de subconjuntos por QR con pivoteo (Exp. B)	6
6.2. Regularización de Tikhonov / ridge / MAP (Exp. A)	6
6.3. Diseño óptimo de experimentos (OED) — el estímulo ES la información (Exp. C)	7
7. El hallazgo del proyecto: w_{II} vive en la dirección plana	8

Resumen

Este documento reúne, con foco en el *porqué*, la matemática que usa el proyecto para decidir **qué parámetros de Wilson–Cowan (WC) se pueden recuperar de los datos, cuáles conviene fijar y qué estímulo inyectar**. El hilo conductor es una sola matriz — la sensibilidad $\mathbf{J} = \partial \mathbf{y} / \partial \boldsymbol{\theta}$ — y su descomposición en valores singulares (SVD). De ahí salen, en cascada, la matriz de información de Fisher (FIM), la cota de Cramér–Rao (CRB), el diagnóstico de identificabilidad práctica, la selección de subconjuntos, la regularización y el diseño óptimo de experimentos (OED). El resultado central es que la FIM **predice, sin entrenar nada**, que w_{II} es el cuello de botella de la identificación — y el barrido de ruido lo confirma. Requisitos previos: M1 (álgebra lineal: autovalores, SVD) y M4 (estimación, ruido, mínimos cuadrados).

1. El problema inverso y la matriz de sensibilidad

Tenemos un modelo directo $\mathbf{y} = \mathbf{g}(\boldsymbol{\theta})$ que, dados los parámetros $\boldsymbol{\theta} \in \mathbb{R}^p$ (en WC los $p = 10$: $w_{EE}, w_{EI}, w_{IE}, w_{II}, \tau_e, \tau_i, a_e, a_i, \theta_e, \theta_i$), integra las EDOs y produce una trayectoria observada $\mathbf{y} \in \mathbb{R}^N$ — la salida $y(t) = E(t) - I(t)$ muestreada en N instantes. El problema **directo** (dados $\boldsymbol{\theta}$, simular $\mathbf{y}$) es fácil. El que resuelve el proyecto es el **inverso**: dado un $\mathbf{y}$ medido con ruido, recuperar $\boldsymbol{\theta}$. Los problemas inversos son notoriamente traicioneros: pueden no tener solución única, y esa no-unicidad no siempre se ve en el error de ajuste.

La pregunta clave — *¿es recuperable cada parámetro?* — se puede responder **antes de ajustar nada**, mirando cuánto se mueve la salida cuando perturbamos cada parámetro. Ese cambio es la *matriz de sensibilidad*, o Jacobiano de salida:

$$\mathbf{J} = \left. \frac{\partial \mathbf{y}}{\partial \boldsymbol{\theta}} \right|_{\boldsymbol{\theta}^*}, \quad \mathbf{J}_{ij} = \frac{\partial y_i}{\partial \theta_j}, \quad \mathbf{J} \in \mathbb{R}^{N \times p}. \quad (1)$$

La **columna** j de $\mathbf{J}$ es un vector de longitud N que dice cómo se deforma *toda la trayectoria* si movemos un poquito θ_j . Es la “huella” que ese parámetro deja en los datos. Se evalúa en el $\boldsymbol{\theta}^*$ verdadero (o en la mejor estimación disponible) y en el proyecto se calcula por diferenciación automática en modo *forward* (`jacfwd`) — exacto, sin diferencias finitas, y eficiente porque hay más salidas que parámetros (ver P4, `neural_ode`).

Sensibilidad relativa. Los 10 parámetros tienen magnitudes muy distintas ($w_{II} \approx 1.2$ frente a $\theta_e \approx 2.8$), así que comparar columnas “en bruto” es injusto. Escalamos cada columna por el propio valor nominal,

$$\tilde{\mathbf{J}}_{\cdot j} = \theta_j^* \frac{\partial \mathbf{y}}{\partial \theta_j}, \quad (2)$$

que equivale a derivar respecto de $\log \theta_j$. Así medimos el efecto de cambios *fraccionales* (adimensionales) y todo el análisis siguiente se hace sobre $\tilde{\mathbf{J}}$.

Observación 1 (Las dos patologías). *Hay dos maneras de que un parámetro sea difícil de identificar, y ambas están escritas en $\mathbf{J}$:*

- **Columna casi nula:** θ_j no deja huella — mover ese parámetro casi no cambia la salida. No hay información sobre él.
- **Dos columnas casi paralelas:** dos parámetros producen el mismo efecto sobre la salida. El ajuste puede aumentar uno y bajar el otro sin que la salida cambie: son indistinguibles como par.

El caso peligroso es el segundo, porque cada parámetro por separado puede tener una columna grande (parecer “sensible”) y aun así ser no identificable. Mirar columna por columna no basta: hay que mirar el espectro de $\mathbf{J}$. De ahí la SVD.

2. SVD de la sensibilidad

Definición 1 (SVD). *Toda matriz $\mathbf{J} \in \mathbb{R}^{N \times p}$ se factoriza como*

$$\mathbf{J} = \mathbf{U} \boldsymbol{\Sigma} \mathbf{V}^\top = \sum_{k=1}^r \sigma_k \mathbf{u}_k \mathbf{v}_k^\top, \quad (3)$$

con $\mathbf{U}$ ($N \times N$) y $\mathbf{V}$ ($p \times p$) ortogonales, y $\boldsymbol{\Sigma} = \text{diag}(\sigma_1 \geq \sigma_2 \geq \dots \geq 0)$ los valores singulares. Los $\mathbf{v}_k$ (vectores singulares derechos) son direcciones en el **espacio de parámetros**; los $\mathbf{u}_k$ (izquierdos), en el **espacio de observaciones** [1].

Interpretación geométrica: círculo $\rightarrow$ elipsoide. La forma más intuitiva de leer la SVD es geométrica (Figura 1). Tomemos todas las perturbaciones de parámetros de tamaño 1 (la bola unitaria en el espacio de $\boldsymbol{\theta}$). Al aplicarles $\mathbf{J}$, esa bola se transforma en un *elipsoide* en el espacio de las salidas. Los semiejes del elipsoide miden $\sigma_1, \sigma_2, \dots$ y apuntan en las direcciones $\mathbf{u}_1, \mathbf{u}_2, \dots$; el eje k proviene de haber empujado los parámetros en la dirección $\mathbf{v}_k$. Dicho de otro modo: una perturbación unitaria en la dirección $\mathbf{v}_k$ produce un cambio de salida de magnitud σ_k .

- σ_k **grande:** mover los parámetros según $\mathbf{v}_k$ mueve mucho la salida $\Rightarrow$ esa combinación es *muy identificable* (el elipsoide es “ancho” en ese eje).

- $\sigma_k \approx 0$: la combinación $\mathbf{v}_k$ *casi no cambia* la salida $\Rightarrow$ **dirección plana**, no identificable (el elipsoide se “aplasta” en ese eje). El propio $\mathbf{v}_k$ dice *qué combinación* de parámetros es la ambigua.

Lo importante: la dirección plana no suele ser “un parámetro”, sino una *combinación* (por ejemplo, “subir w_{II} y compensar con a_i ”). Por eso el diagnóstico correcto vive en la SVD y no en las columnas sueltas.




Figura 1: Geometría de la SVD: la matriz $\mathbf{J}$ manda el círculo unitario del espacio de parámetros a un elipsoide en el espacio de observaciones. Los semiejes son los valores singulares σ_k y sus orientaciones los vectores $\mathbf{u}_k$; el número de condición $\kappa = \sigma_{\text{máx}}/\sigma_{\text{mín}}$ mide cuán elongado (mal condicionado) es.

Número de condición. La razón entre el eje mayor y el menor,

$$\kappa(\mathbf{J}) = \frac{\sigma_{\text{máx}}}{\sigma_{\text{mín}}}, \quad (4)$$

resume en un número cuán elongado es el elipsoide. $\kappa \approx 1$ es una bola (todas las direcciones igual de determinadas); κ grande significa que hay direcciones *muchísimo* peor determinadas que otras — problema mal condicionado. En WC, la SVD de $\tilde{\mathbf{J}}$ da $\kappa \approx 1.2 \times 10^3$ (moderadamente mal condicionado) y señala que el valor singular más chico, σ_{10} , está **dominado por** w_{II} , con acoples débiles $a_e - \tau_e - w_{EE}$ y $a_i - \tau_i - \theta_i$. Este diagnóstico es puramente geométrico: no se entrenó ningún modelo todavía.

3. Matriz de información de Fisher (FIM)

Definición y forma operativa

Supongamos ruido de observación gaussiano i.i.d. de varianza σ_ϵ^2 : $\mathbf{y} = \mathbf{g}(\boldsymbol{\theta}) + \boldsymbol{\epsilon}$, $\boldsymbol{\epsilon} \sim \mathcal{N}(0, \sigma_\epsilon^2 \mathbf{I})$. La *matriz de información de Fisher* cuantifica cuánta información traen los datos sobre $\boldsymbol{\theta}$ [2]. Su definición es el valor esperado del producto exterior del gradiente de la log-verosimilitud $\log L$, y para este modelo se reduce a algo muy simple:

$$\mathcal{I}(\boldsymbol{\theta}) = \mathbb{E} \left[\left(\frac{\partial \log L}{\partial \boldsymbol{\theta}} \right) \left(\frac{\partial \log L}{\partial \boldsymbol{\theta}} \right)^\top \right] = \frac{1}{\sigma_\epsilon^2} \mathbf{J}^\top \mathbf{J}. \quad (5)$$

La segunda igualdad es la clave operativa: **para ruido gaussiano, la FIM es (salvo el factor $1/\sigma_\epsilon^2$) el producto $\mathbf{J}^\top \mathbf{J}$** . No hace falta calcular esperanzas: basta el Jacobiano de sensibilidad que ya teníamos.

Por qué la FIM “es la curvatura del error”

La log-verosimilitud es $\log L(\boldsymbol{\theta}) = -\frac{1}{2\sigma_\varepsilon^2} \|\mathbf{y} - \mathbf{g}(\boldsymbol{\theta})\|^2 + \text{cte}$, así que *maximizar* la verosimilitud es *minimizar* la superficie de error $L(\boldsymbol{\theta}) = \frac{1}{2\sigma_\varepsilon^2} \|\mathbf{y} - \mathbf{g}(\boldsymbol{\theta})\|^2$ sobre el espacio de parámetros. Cerca del óptimo $\hat{\boldsymbol{\theta}}$ el gradiente se anula, así que el desarrollo de Taylor a segundo orden deja solo el término cuadrático:

$$L(\boldsymbol{\theta}) \approx L(\hat{\boldsymbol{\theta}}) + \frac{1}{2} (\boldsymbol{\theta} - \hat{\boldsymbol{\theta}})^\top \mathbf{H} (\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}), \quad \mathbf{H} = \text{Hessiano} \approx \mathcal{I}. \quad (6)$$

Es decir: **la FIM es la matriz de curvatura del paisaje de error alrededor del óptimo**, un paraboloide cuya forma la fija $\mathcal{I}$. La lectura es directa:

- dirección **muy curvada** (autovalor grande) $\Rightarrow$ el error sube rápido al alejarse $\Rightarrow$ combinación *bien determinada*, pico agudo de verosimilitud;
- dirección **plana** (autovalor chico) $\Rightarrow$ uno se mueve mucho sin que suba el error $\Rightarrow$ *no identificable*, el “valle plano”.

Fisher + SVD son una sola herramienta

Sustituyendo la SVD (3) en (5) y usando que $\mathbf{U}^\top \mathbf{U} = \mathbf{I}$:

$$\mathcal{I} = \frac{1}{\sigma_\varepsilon^2} \mathbf{V} \boldsymbol{\Sigma}^2 \mathbf{V}^\top \implies \underbrace{\lambda_k(\mathcal{I})}_{\text{autovalor}} = \frac{\sigma_k^2}{\sigma_\varepsilon^2}, \quad \text{autovectores} = \mathbf{v}_k. \quad (7)$$

O sea: **los autovectores de la FIM son exactamente las direcciones $\mathbf{v}_k$ de la SVD**, y sus autovalores son los σ_k^2 escalados por el ruido. Los ejes propios del paraboloide de error son las combinaciones $\mathbf{v}_k$; su curvatura es $\sigma_k^2/\sigma_\varepsilon^2$. Una dirección plana (σ_k chico) es, a la vez, una dirección de poca curvatura y de poca información. Por eso “analizar la FIM” y “hacer la SVD de $\mathbf{J}$ ” son la misma operación, y todo el diagnóstico se puede hacer con una sola factorización. El método está tomado de Plate et al. para UDEs [10].




Figura 2: El “valle plano” de la FIM en WC (figura del proyecto). El paisaje de error tiene una dirección muy curvada (bien identificable) y una casi plana; el eje del valle es la combinación $\mathbf{v}_{10}$, dominada por w_{II} . Moverse a lo largo del valle casi no cambia el error: esa es la firma geométrica de la no identificabilidad práctica.

Observación 2 (Valor singular vs. autovalor — no confundir de quién es cada cosa). $\mathbf{J}$ es rectangular ($N \times p$): tiene **valores singulares** σ_k (una matriz rectangular no tiene autovalores). La FIM $= \mathbf{J}^\top \mathbf{J} / \sigma_\varepsilon^2$ es cuadrada y simétrica ($p \times p$): tiene **autovalores** λ_k . La relación es $\lambda_k(\mathcal{I}) = \sigma_k^2 / \sigma_\varepsilon^2$: el autovalor de la FIM es el valor singular de $\mathbf{J}$ al cuadrado, dividido por la

varianza del ruido. Misma información, elevada al cuadrado y escalada. Cuidado también con la notación: σ_k es un valor singular, mientras que σ_ε es el desvío del ruido; son objetos distintos que comparten letra.

4. Cota de Cramér–Rao: la incertidumbre correcta

¿Cuál es el *mejor* error posible al estimar θ , aun con el estimador ideal? La *cota de Cramér–Rao* (CRB) acota por debajo la covarianza de cualquier estimador insesgado [3, 4]:

$$\text{Cov}(\hat{\theta}) \succeq \mathcal{I}^{-1} = \sigma_\varepsilon^2 (\mathbf{J}^\top \mathbf{J})^{-1}. \quad (8)$$

(El símbolo $\succeq$ significa que la diferencia $\text{Cov}(\hat{\theta}) - \mathcal{I}^{-1}$ es semidefinida positiva.) La **desviación estándar mínima** del parámetro j es la raíz del elemento diagonal de la *inversa*:

$$\text{std}(\hat{\theta}_j) \geq \sigma_\varepsilon \sqrt{[(\mathbf{J}^\top \mathbf{J})^{-1}]_{jj}}. \quad (9)$$

La conexión con la SVD es transparente: invertir la FIM es invertir Σ^2 , así que las direcciones planas (σ_k chico) se transforman en **varianza enorme**. Curvatura chica $\rightarrow$ incertidumbre grande. El valle plano de la Figura 2 se paga como incertidumbre gigante en w_{II} .

Observación 3 (Por qué la diagonal de la INVERSA, y no la norma de la columna). *Es el punto conceptual más importante del documento. Hay dos medidas que se confunden con facilidad:*

- $\mathcal{I}_{jj}$, o equivalentemente $\|\mathbf{J}_{\cdot j}\|^2$: la sensibilidad marginal “bruta” de θ_j . **Ignora las correlaciones.**
- $(\mathcal{I}^{-1})_{jj}$: la incertidumbre real de $\hat{\theta}_j$ teniendo en cuenta que se estima junto con todos los demás.

Si θ_j está muy correlacionado con otro parámetro, $(\mathcal{I}^{-1})_{jj}$ se dispara aunque su columna $\|\mathbf{J}_{\cdot j}\|$ sea grande: puede tener mucha señal, pero señal redundante, imposible de separar de la del vecino. Solo la inversa descuenta las correlaciones.

El ejemplo del proyecto: “box” vs. “chirp”. Este error tuvo consecuencias concretas al elegir el estímulo para identificar w_{II} (experimento C). La métrica ingenua $\|\text{columna}\|$ decía que el pulso cuadrado (“box”) era el mejor estímulo, porque produce una señal de amplitud grande. Pero la CRB correcta $\sqrt{\text{diag}(\mathcal{I}^{-1})}$ dice lo contrario: el mejor es el **chirp** (barrido de frecuencia). ¿Por qué? El box excita E e I casi en fase ($E \approx I$), de modo que sus sensibilidades quedan *correlacionadas* — señal grande pero redundante. El chirp, de banda ancha, *decorrelaciona* las direcciones y por eso baja la CRB de w_{II} . Moraleja: identificabilidad = sensibilidad *decorrelacionada*, no amplitud.

5. Identificabilidad estructural vs. práctica

Conviene separar dos preguntas que suenan parecido pero no lo son:

- **Identificabilidad estructural.** En el mundo ideal — datos infinitos y *sin ruido* — ¿existe un único θ que produce esa salida? Es una propiedad de la *estructura* del modelo. Por ejemplo, dos parámetros que solo aparecen como producto $w_1 w_2$ nunca se separan: son estructuralmente no identificables.
- **Identificabilidad práctica.** Con *ruido finito y datos finitos*, ¿está el parámetro bien determinado? Un parámetro puede ser estructuralmente identificable y aun así vivir en una dirección casi plana, con lo cual el ruido lo vuelve *prácticamente* no identificable. Es lo que miden la FIM y la CRB.

El caso de w_{II} . En WC, w_{II} es **estructuralmente identificable** — se lo recupera bien usando múltiples trayectorias con datos limpios — pero **prácticamente mal identificable bajo ruido**: su CRB es alta y, como veremos en §7, su recuperación se degrada dramáticamente cuando sube σ_ε . La distinción es fundamental porque los remedios difieren: contra la no identificabilidad estructural hay que *cambiar el modelo o la parametrización*; contra la práctica alcanza con *más/mejores datos* (OED), *fijar* o *regularizar*.

Profile likelihood. El método canónico para diagnosticar identificabilidad práctica es el *profile likelihood* de Raue et al. [5]: se fija θ_j en un rango de valores, se reoptimiza *todo el resto* en cada valor y se traza la verosimilitud resultante. Un perfil con un **valle marcado** en torno a $\hat{\theta}_j$ indica que el dato “castiga” alejarse $\Rightarrow$ identificable. Un perfil **plano** indica que se puede mover θ_j sin empeorar el ajuste (reacomodando los demás) $\Rightarrow$ no identificable. Es la versión *global y no lineal* de mirar el autovalor chico de la FIM: la FIM es la aproximación local cuadrática (6), y el profile likelihood explora el valle completo, incluso lejos del óptimo.

6. Remedios: qué fijar, cómo regularizar, qué estímulo usar

Diagnosticado el problema (§2–5), hay tres familias de remedios, que en el proyecto corresponden a los experimentos B, A y C. La idea unificadora es que los tres *agregan información* a las direcciones planas de la FIM.

6.1. Selección de subconjuntos por QR con pivoteo (Exp. B)

Si liberar los 10 parámetros es mal condicionado, una estrategia establecida es **fijar** los peor identificables en un valor previo/nominal y estimar solo el subconjunto bien condicionado [6]. ¿Cuáles fijar? La respuesta la da la geometría de **J**.

QR con pivoteo de columnas. Se aplica la factorización $\tilde{\mathbf{J}}\mathbf{\Pi} = \mathbf{QR}$, donde $\mathbf{\Pi}$ es una permutación que *reordena* las columnas (parámetros) de mayor a menor independencia lineal (pivotes $|R_{ii}|$ decrecientes) [1]. La *cola* del ranking — los últimos pivotes — son los parámetros que más “se explican” con combinaciones de los demás: los candidatos naturales a fijar. Es una selección *greedy* por ortogonalización, equivalente a mirar los $\mathbf{v}_k$ de los σ_k chicos (§2) y fijar un representante de cada dirección débil. En WC, el QR-pivoteo dio el orden $\theta_e > \dots > a_e > w_{II}$, con w_{II} en último lugar y cola $\{w_{EI}, a_e, w_{II}\}$.

Observación 4 (Regla práctica: fijar de más empeora). *Fijar un representante mínimo de cada acople débil ayuda; fijar de más sobre-restringe y empeora. En WC, fijar w_{II} o a_i (ambos viven en la ecuación de la población inhibitoria) baja mucho el error del resto. Pero fijar los dos a la vez rompe el acople $a_i \leftrightarrow w_{II}$ y dispara el error: el subconjunto queda sobre-restringido. La regla es fijar uno por acople débil, no todos.*

6.2. Regularización de Tikhonov / ridge / MAP (Exp. A)

En lugar de fijar un parámetro de golpe, se puede **penalizar** su alejamiento de un valor previo θ^0 (regularización de Tikhonov / ridge) [7]:

$$\hat{\theta} = \arg \min_{\theta} \underbrace{\|\mathbf{y} - \mathbf{g}(\theta)\|^2}_{\text{ajuste}} + \lambda \underbrace{\|\theta - \theta^0\|^2}_{\text{penalización}}. \quad (10)$$

Tres lecturas equivalentes del mismo objeto:

- **Ridge / Tikhonov:** sumar $\lambda \mathbf{I}$ a la FIM ($\mathcal{I} + \lambda \mathbf{I}$) le agrega curvatura a las direcciones planas y la vuelve invertible / mejor condicionada.

- **MAP bayesiano:** (10) es el máximo a posteriori con un *prior* gaussiano $\theta \sim \mathcal{N}(\theta^0, \tau^2 \mathbf{I})$, con $\lambda = \sigma_\varepsilon^2 / \tau^2$. El prior aporta la información que faltaba en el valle.
- **Sesgo–varianza:** se agrega *sesgo* (hacia θ^0) a cambio de *menos varianza*, y eso conviene justo en las direcciones mal condicionadas.

Observación 5 (El continuo $\lambda \rightarrow \infty \equiv$ fijar). Con $\lambda = 0$ se recupera el ajuste libre (10 parámetros sueltos); con $\lambda \rightarrow \infty$ el parámetro queda clavado en θ_j^0 , es decir, equivale a fijarlo (§6.1). La regularización es entonces el continuo entre “todo libre” y “fijar”, y un λ intermedio suele ser óptimo.




Figura 3: Barrido del parámetro de regularización λ sobre w_{II} (figura del proyecto). El error de los demás parámetros baja de forma monótona con λ y *satura* en el valor que se obtiene al fijar w_{II} : es la confirmación empírica de que $\lambda \rightarrow \infty$ equivale a fijar. El óptimo práctico está en $\lambda \approx 1$.

6.3. Diseño óptimo de experimentos (OED) — el estímulo ES la información (Exp. C)

La FIM depende de la trayectoria, y la trayectoria depende del *estímulo* $P(t), Q(t)$. Luego **elegir el estímulo es elegir la información**: es el diseño óptimo de experimentos (OED) o diseño de entrada óptimo [8, 9, 10]. A diferencia de fijar o regularizar — que reparten mejor información escasa — el OED *crea* información nueva. Se optimiza un funcional escalar de la FIM:

A-óptimo	minimizar $\text{tr}(\mathcal{I}^{-1})$ — varianza media de los estimadores (suma de CRB^2)
D-óptimo	maximizar $\det(\mathcal{I})$ — mínimo volumen del elipsoide de confianza
E-óptimo	maximizar $\lambda_{\min}(\mathcal{I})$ — mejora la <i>peor</i> dirección (la más débil)

Excitación persistente (Ljung). Para identificar un sistema hay que *recorrer* su espacio de estados: una entrada demasiado pobre (casi constante) deja direcciones sin excitar y la FIM sin rango completo. Una entrada es *persistentemente excitante* si su contenido espectral cubre las dinámicas del sistema [8]. Por eso los estímulos de banda ancha (chirp, secuencias pseudoaleatorias PRBS, Poisson) condicionan mucho mejor la FIM que un pulso cuadrado, aunque este tenga

más amplitud (Figura 4): lo que importa no es la energía, sino la *decorrelación* de las direcciones sensibles. En WC, además, todos los estímulos deben ser *realizables con optogenética* (on/off, ≥ 0), lo que restringe el diseño a señales no negativas.




Figura 4: Número de condición κ de la FIM por familia de estímulo (figura del proyecto). Los estímulos de banda ancha (chirp, Poisson, PRBS) dan κ mucho menor — FIM mejor condicionada — que el box/square, pese a que estos últimos tienen mayor amplitud. La banda ancha decorrelaciona las direcciones sensibles.

OED ponderado al cuello de botella. A ruido moderado, una *mezcla* de estímulos complementarios maximiza la identificabilidad conjunta. Pero a ruido extremo, el cuello de botella (w_{II}) necesita *peso extra* en su dirección propia (típicamente más excitación por Q , la entrada a la población inhibitoria). El OED ponderado — que sacrifica un poco de información global para volcarla en la dirección débil — muestra un óptimo interior (Figura 5): ni cobertura uniforme ni todo al cuello de botella, sino un punto medio. Es el mismo compromiso sesgo–varianza de la regularización, ahora en el diseño del experimento.




Figura 5: OED ponderado (figura del proyecto): error de identificación en función del peso ρ dado a la dirección del cuello de botella. La curva tiene forma de V con óptimo interior en $\rho \approx 0.5$: repartir toda la información de manera uniforme ($\rho \rightarrow 0$) o volcarla entera al cuello de botella ($\rho \rightarrow 1$) son ambos peores que el balance intermedio.

7. El hallazgo del proyecto: w_{II} vive en la dirección plana

Todo el aparato anterior converge en un resultado limpio y verificable, que es el corazón de esta etapa del proyecto.

Predicho sin entrenar. La SVD de la FIM (evaluada en θ^* , *antes de ajustar ningún modelo*) señaló que el valor singular más chico está dominado por w_{II} : el parámetro vive en la dirección plana del valle (Figura 2). Este es un diagnóstico puramente geométrico — la FIM *predice* el cuello de botella sin que se haya entrenado un solo Neural ODE. Es la promesa de la herramienta: saber de antemano qué se va a poder recuperar y qué no.

Confirmado bajo ruido. El barrido de ruido (Figura 6) confirma la predicción de manera contundente. Con datos limpios, w_{II} se recupera con un error del 0.8%; al subir el ruido a $\sigma_\epsilon = 0.10$, su error se dispara al 41%, mientras que los parámetros que viven en direcciones curvadas se mantienen estables. La FIM había dicho “ w_{II} es frágil”, y el experimento la confirmó. Predicción y verificación cierran el círculo diagnóstico.




Figura 6: Error de identificación por parámetro en función del nivel de ruido σ_ϵ (figura del proyecto). w_{II} (el parámetro de la dirección plana) es de lejos el que peor escala: pasa de $\sim 0.8\%$ con datos limpios a $\sim 41\%$ a $\sigma_\epsilon = 0.10$. Los parámetros en direcciones curvadas apenas se degradan. La FIM había anticipado exactamente esta jerarquía.

Pero la fragilidad no se propaga al control (adelanto de B5). Sería fácil concluir que un w_{II} mal identificado arruina cualquier uso posterior del modelo. *No es así*, y este es un matiz importante. El objetivo último del proyecto no es estimar θ por sí mismo, sino usar el modelo identificado para **controlar** el sistema en lazo cerrado (un controlador IMC que lleva el régimen al objetivo theta-gamma). Resulta que la dirección plana en la que vive w_{II} es, en buena medida, una dirección a la que el controlador es *insensible*: el mismo mecanismo (colinealidad $E \approx I$) que hace a w_{II} difícil de estimar también lo hace poco relevante para el comportamiento entrada-salida que el control necesita reproducir. Por eso la incertidumbre grande en w_{II} **no se propaga** al desempeño de control. La lección es que “identificabilidad” debe leerse *orientada a la tarea*: un parámetro puede ser prácticamente no identificable y, aun así, irrelevante para el objetivo final. El desarrollo cuantitativo de este punto está en B5 (validación orientada al control).

Referencias

- [1] G. H. Golub y C. F. Van Loan, *Matrix Computations*, 4.^a ed., Johns Hopkins University Press, 2013.
- [2] R. A. Fisher, “On the mathematical foundations of theoretical statistics”, *Phil. Trans. R. Soc. A*, 222:309–368, 1922.
- [3] C. R. Rao, “Information and the accuracy attainable in the estimation of statistical parameters”, *Bull. Calcutta Math. Soc.*, 37:81–89, 1945.
- [4] H. Cramér, *Mathematical Methods of Statistics*, Princeton University Press, 1946.
- [5] A. Raue *et al.*, “Structural and practical identifiability analysis of partially observed dynamical models by exploiting the profile likelihood”, *Bioinformatics*, 25(15):1923–1929, 2009.
- [6] Y. Chu y J. Hahn, “Parameter set selection for estimation of nonlinear dynamic systems”, *AIChE Journal*, 53(11):2858–2870, 2007.
- [7] A. N. Tikhonov y V. Y. Arsenin, *Solutions of Ill-Posed Problems*, Winston & Sons, 1977.
- [8] L. Ljung, *System Identification: Theory for the User*, 2.^a ed., Prentice Hall, 1999.
- [9] G. Franceschini y S. Macchietto, “Model-based design of experiments for parameter precision: State of the art”, *Chem. Eng. Sci.*, 63(19):4846–4872, 2008.
- [10] C. Plate *et al.*, “Optimal experimental design for universal differential equations”, 2024 (preprint arXiv).