

R2 — Datos reales experimentales

Identificación de Wilson–Cowan por salida sobre LFP: el hallazgo del *driver* débil

Proyecto Wilson–Cowan — Iniciación a la I+D ITBA

12 de julio de 2026

Índice

1. Los datos: <code>data8_filtered.mat</code>	1
2. El problema: identificación por salida	3
3. Validación por partes	4
3.1. Coherencia $u \rightarrow s$	4
3.2. Baseline ARX (modelo lineal)	4
4. El hallazgo central: predicción vs. simulación libre	4
5. Por qué el <i>rollout</i> libre "no anda" (y por qué está bien)	6
6. Implicaciones para los dos protocolos	6
7. Conexión con la teoría de identificabilidad	7
8. Estado y próximos pasos	7

Resumen

Este documento cuenta la primera tanda de trabajo con **datos experimentales reales**: tres grabaciones de estímulo *chirp* y respuesta LFP (`data8_filtered.mat`). A diferencia de todo lo sintético, acá solo se observa un escalar s (el LFP), no el estado $[I, E]$: esto es identificación **por salida**, y obliga a repensar el pipeline. El resultado central no es un número de ajuste sino un *hallazgo sobre los datos*: el estímulo u gobierna solo $\sim 10\%$ de la respuesta s en modo simulación; el resto es dinámica interna/estocástica. Por eso el modelo se identifica en **modo predicción a horizonte corto** (donde alcanza $R^2 \approx 0.85$), y el *rollout* libre queda topado en $R^2 \sim 0.1$ — no por un fallo del modelo, sino por una propiedad medible del sistema. Cerramos conectando esto con la teoría de identificabilidad del proyecto (direcciones planas en la FIM) y con los próximos pasos.

1. Los datos: `data8_filtered.mat`

Qué nos entregaron

El archivo `data8_filtered.mat` (MATLAB v5, solo arrays numéricos planos, sin *structs* ni *cells*) contiene **tres grabaciones sucesivas** de un experimento de estimulación tipo *chirp*. Cada grabación es un par (u_i, s_i) :

- u_i : el **estímulo aplicado**, un *chirp* que barre de 1 a 10 Hz. Es **no negativo**, con offset: $u = 0.1 + 0.1 \sin(\text{fase}) \in [0, 0.2]$. Arranca en 0.1 y $(\text{máx} - \text{mín})/2 = 0.100$ exacto. Esta forma —prende/apaga alrededor de un valor medio positivo— es justo el estilo **optogenético** que persigue el proyecto: no hay corrientes negativas, se ilumina más o menos.
- s_i : la **respuesta medida**, un **escalar** (LFP, potencial de campo local). Viene filtrada pasa-banda $[0.5, 19]$ Hz, por eso tiene media ≈ 0 y amplitud ± 0.05 . Es el análogo experimental de la salida $y = E - I$ del modelo (ver el preámbulo canónico, sección de ecuaciones de WC más abajo).
- $f_s = 1250$ Hz (variable `fsd`, `uint16`). Duraciones 19.15/19.86/16.23 s, es decir $N = 23938/24822/20287$ muestras. Sin NaN/Inf.

variable	shape	tipo	qué es
<code>fsd</code>	$(1, 1)$	<code>uint16</code>	$f_s = 1250$ Hz
<code>u1, u2, u3</code>	$(N, 1)$	<code>float64</code>	estímulos <i>chirp</i> $1 \rightarrow 10$ Hz, $u \in [0, 0.2]$
<code>s1, s2, s3</code>	$(N, 1)$	<code>float64</code>	respuestas LFP, filtradas $[0.5, 19]$ Hz

Cuadro 1: Contenido verificado del `.mat`. Los tres N son distintos (grabaciones de distinta duración).

Diagnóstico: la respuesta rastrea el chirp

Antes de identificar nada conviene *mirar* los datos. La figura 1 superpone u , s y sus espectrogramas. Lo importante: la respuesta s **rastrea la frecuencia instantánea del chirp** —la cresta del espectrograma de s sube de ~ 1 a ~ 6 –7 Hz siguiendo al estímulo. Esto confirma que hay una **respuesta forzada**: existe un mapa entrada→salida y el problema no es una ilusión. (Guardarse este dato: la respuesta *sigue* al chirp, pero eso no dice *cuánta* de la varianza total explica el estímulo. Esa distinción es todo el documento.)




Figura 1: Diagnóstico de los datos reales: arriba, u (chirp) y s (LFP filtrada) en el tiempo; abajo, sus espectrogramas. La cresta espectral de la respuesta acompaña la frecuencia instantánea del chirp, evidencia de respuesta forzada. (figura del proyecto)

Conversión a .npz

El script `load_real_data.py` no identifica nada: solo empaqueta el `.mat` a un `.npz` cómodo, con opción de decimar. Los cuidados que importan:

1. u_i, s_i son vectores columna $(N, 1)$: se aplanan a 1-D con `ravel`.
2. `fsd` es `uint16`: castear a `float` antes de dividir.
3. La **decimación** usa un anti-alias IIR (Chebyshev, fase cero). Como la banda útil llega a 19 Hz, con $f_s^{\text{out}} \geq 250$ Hz (Nyquist 125 Hz) sobra margen. Se generan dos datasets: `data8_fs250.npz` ($\times 5$, para producción) y `data8_fs125.npz` ($\times 10$, para iterar rápido). El *ringing* del IIR lleva u a ≈ -0.001 ; si se necesita $u \geq 0$ estricto se decima con FIR o se clipea.

Se trabajó a 125 Hz para iterar y a 250 Hz para producción; en ambos el *rollout* de una grabación es de $\sim 2\text{--}5$ k pasos, viable con *backprop*.

2. El problema: identificación por salida

Ecuaciones y decisiones de modelado

El modelo es Wilson–Cowan en su forma canónica, con estado $\mathbf{x} = [I, E]$ y sigmoidea $S_a(u) = 1/(1 + e^{-au})$:

$$\dot{I} = \frac{1}{\tau_i} (-I + S_i(w_{IE}E - w_{II}I + Q(t) - \theta_i) - k_i), \quad (1)$$

$$\dot{E} = \frac{1}{\tau_e} (-E + S_e(w_{EE}E - w_{EI}I + P(t) - \theta_e) - k_e), \quad (2)$$

con k_e, k_i derivados (no aprendidos) para que $E = I = 0$ sea el reposo sin estímulo, y salida $y = E - I$. Sobre este esqueleto se toman las decisiones que conectan el modelo con los datos:

- **Entrada:** el estímulo entra a la población excitatoria, $P = c_P u$, $Q = 0$, con c_P una ganancia libre (decisión D2).
- **Salida:** $s = c_{\text{out}} (E - I)$, con c_{out} libre y offset $b = 0$ (la señal ya viene sin DC porque está pasa-banda; decisión D3).
- **Comparación:** el $\hat{y}$ simulado se compara en el mismo dominio filtrado $[0.5, 19]$ Hz que s , para que el modelo no tenga que "explicar" componentes que fueron filtradas (decisión D4).

Por qué esto rompe el pipeline de estado completo

La diferencia de fondo con los datos sintéticos: allá se medía el estado completo $[I, E]$, así que el *multiple shooting* podía **resetear** x_0 desde el estado observado en cada ventana y comparar contra $[I, E]$ directamente. Con datos reales **eso no existe**: solo tenemos el escalar $s \approx y$. Consecuencias:

1. El estado inicial $[I_0, E_0]$ de cada grabación es **desconocido**: pasa a ser una variable a estimar.
2. El *multiple shooting* tal cual no aplica —no hay estados que resetear. Se pasa a *multiple shooting por salida*: el x_0 de *cada ventana* es una **variable latente** que se optimiza, con una penalización de **continuidad** que ata el fin de una ventana con el inicio de la siguiente.
3. Aparece un **modelo de observación** ($s = c_{\text{out}}(E - I)$) y escalas nuevas que en lo sintético no existían: c_P , c_{out} y la escala de tiempo (absorbida por τ_e, τ_i libres).

Esto es identificación de sistemas no lineal *por salida* estándar (*gray-box*), el marco clásico de Ljung [1]. Pero **no** es lo que corría el repo, así que se escribió un trainer nuevo: `train_real_output.py`. Su núcleo es trocear cada grabación en ventanas cortas (W pasos, ~ 0.8 s), rodar la EDO en cada ventana desde su x_0 latente, comparar y y s *demediados* por ventana (aproxima el pasa-banda sin filtro global), y sumar un término de continuidad $\lambda_{\text{cont}} \|x_0^{(k+1)} - \text{fin}(x^{(k)})\|^2$ que reata las ventanas para que los parámetros WC sigan siendo globales.

Observación 1 (Por qué ventanas y no un rollout largo). *Un rollout de ~ 2400 pasos ajustado con MSE en el tiempo **colapsa a salida cero**: si la fase no coincide casi exacto, predecir 0 tiene menos error que una oscilación desfasada, y el gradiente cae al mínimo trivial. Cortar en ventanas cortas hace la fase local (tratable), batchea (mucho más rápido), y la continuidad recompone el todo.*

3. Validación por partes

Antes de invertir en el pipeline WC completo se validaron los supuestos con experimentos baratos, de menor a mayor compromiso.

3.1. Coherencia $u \rightarrow s$

La coherencia espectral entre u y s (estimador de Welch) es **alta a baja frecuencia**: pico ≈ 0.96 a ~ 1.7 Hz, y decae al subir. Como el chirp es no estacionario, la coherencia de Welch está sesgada, pero el mensaje es robusto: **hay relación entrada–salida**, coincidente con lo que muestra el espectrograma (fig. 1).

3.2. Baseline ARX (modelo lineal)

El techo lineal se estima con un **ARX** (auto-regresivo con entrada exógena, órdenes n_a para el pasado de s y n_b para el de u), ajustado por mínimos cuadrados:

orden (n_a, n_b)	R^2 <i>teacher-forcing</i> (in-sample)	R^2 cruzado (fit rec0 $\rightarrow$ rec1/2)
(0, 40) — solo FIR de u	0.14	0.10
(2, 20)	0.987	0.987/0.988
(4, 40)	~ 1.00	0.998/0.999

Cuadro 2: ARX en modo *teacher-forcing* (predicción a 1 paso). El $R^2 \approx 0.99$ y su reproducibilidad *cruzada* sugieren un ajuste inmejorable... pero ese número usa el pasado *real* de s .

A primera vista parece cerrado: $R^2 \approx 0.99$, y el ajuste **cruzado** (parámetros de la grabación 0 aplicados a las otras) es casi idéntico $\Rightarrow$ los parámetros son **reproducibles entre grabaciones**. La trampa está en que ese R^2 es **predicción a un paso**: en cada instante usa el valor *medido* de s un instante antes. Es exactamente la letra chica que separa este documento en dos.

4. El hallazgo central: predicción vs. simulación libre

El experimento decisivo

Tomemos el **mismo** ARX de la tabla 2 y corrámoslo en **simulación libre**: solo con u , realimentando su *propia* salida (que es exactamente lo que hace un *rollout* de Wilson–Cowan). El contraste es brutal:

modo	R^2
<i>teacher-forcing</i> (predicción 1 paso, usa el pasado real de s)	0.99–1.00
simulación libre (solo u , realimenta su salida)	0.04–0.11

Cuadro 3: El mismo modelo, dos métricas. La predicción a 1 paso "calca" s ; la simulación libre apenas llega a $R^2 \sim 0.1$.

La figura 2 lo muestra crudo: arriba, la predicción a un paso se *superpone* a s ; abajo, la simulación libre produce una oscilación limpia con la frecuencia correcta pero **desfasada y sin la estructura fina** de s .




Figura 2: **El hallazgo central.** Arriba: predicción a 1 paso (*teacher-forcing*) sobre s ; el modelo calca la señal ($R^2 \approx 0.99$). Abajo: simulación libre desde u ; oscilación con la frecuencia correcta pero desfasada, $R^2 \approx 0.1$. La brecha entre ambas mide cuánto de s gobierna u . (figura del proyecto)

Qué significa

El estímulo u explica solo **~10 %** de la varianza de s en modo simulación. El resto lo hace la **dinámica interna/estocástica** del sistema.

La evidencia complementaria: sin la parte auto-regresiva ($n_a = 0$, solo FIR de u) el R^2 cae a 0.14 (tabla 2, primera fila). Es decir, la parte que "usa el pasado de s " —la dinámica recurrente— hace casi todo el trabajo; u sola aporta poco.

El WC en las dos métricas

Con el trainer por salida (multiple shooting, estado latente por ventana), Wilson–Cowan se comporta según qué métrica se le exija:

métrica	R^2 WC	comentario
predicción a horizonte corto (ventana ~ 16 pasos = 128 ms)	$\approx \mathbf{0.85}$	la dinámica WC <i>sí</i> es identificable
<i>rollout</i> libre de toda la traza (solo u)	$\approx 0.01\text{--}0.05$	cerca del techo real (~ 0.1)

Cuadro 4: WC identificado por salida. En el marco correcto (predicción a horizonte corto) alcanza $R^2 \approx 0.85$; en *rollout* libre queda cerca del techo real de la tarea.

La lectura clave: el WC en *rollout* libre daba ~ 0 **porque la tarea tiene techo ~ 0.1** , no porque el trainer o la hipótesis $u \rightarrow E$ estuvieran mal. **No es un fallo del modelo: es una propiedad medible de los datos.**

5. Por qué el *rollout* libre "no anda" (y por qué está bien)

Tres cosas se confundieron al principio; conviene separarlas:

1. **Colapso a salida cero.** Ajustar una señal oscilatoria con MSE en el tiempo, si la fase no calza casi exacto, premia "predecir 0" por sobre una oscilación desfasada $\Rightarrow$ mínimo trivial. Se mitiga con una *loss* normalizada / de correlación y con las ventanas cortas.
2. **Degeneración con estado latente.** Ventanas cortas + x_0 latente ajustan *localmente* incluso con un modelo inestable o incorrecto (los resets enmascaran la inestabilidad); el *rollout* libre después diverge. Se mitiga con continuidad fuerte, regularización de parámetros y *curriculum* de longitud de ventana.
3. **El techo real.** Aun arreglando 1 y 2, la simulación libre desde u no puede pasar de $R^2 \sim 0.1$ **porque u no gobierna a s** . Esto lo confirma el ARX (tabla 3): no es un problema numérico, es la física de los datos.

El punto 3 es el que hay que internalizar: un techo bajo en simulación libre es un *dato del experimento* (input débil), no un veredicto sobre el modelo.

6. Implicaciones para los dos protocolos

El proyecto pidió dos protocolos de validación. El hallazgo reordena las expectativas:

- **Protocolo A — generalización entre trayectorias (leave-one-out).** *Viable* en modo predicción. Se ajusta un solo juego de parámetros sobre 2 grabaciones y se mide en la tercera, rotando. El techo cruzado es ≈ 0.99 y los parámetros son reproducibles entre las 3 grabaciones. Es el protocolo **fuerte** para estos datos.
- **Protocolo B — continuación temporal (forecast por rollout libre).** *Limitado* por el techo de simulación (~ 0.1). "Continuar la trayectoria" desde u solo no es alcanzable con alta precisión: es propiedad de los datos, no del modelo. La métrica *honest* de forecast es a **horizonte corto** (predecir los próximos k pasos dado el pasado reciente), no continuación indefinida.

Nada de esto invalida el objetivo: la identificación paramétrica se hace en **modo predicción**, que es el marco estándar (*prediction-error method* [1]). Lo que cambia es el criterio de éxito y la expectativa sobre el *rollout* libre.

7. Conexión con la teoría de identificabilidad

Que u sea un *driver* débil y que el régimen sea **casi lineal de 2º orden** tiene una consecuencia directa sobre la identificabilidad. De los 10 parámetros de WC, los datos solo restringen $\sim 4\text{--}5$ **combinaciones efectivas**: los 2 polos de la dinámica linealizada más las ganancias c_P, c_{out} . El resto de las direcciones en el espacio de parámetros queda **sin excitar**.

En el lenguaje del proyecto: habrá **direcciones planas** en la Matriz de Información de Fisher (FIM) del ajuste real, exactamente el fenómeno de mal condicionamiento que se analiza con SVD y se acota con Cramér–Rao (ver M6). El input débil es una fuente de no identificabilidad *práctica* adicional a la estructural: aunque la parametrización fuera perfecta, un estímulo que aporta $\sim 10\%$ de la varianza no puede tensar todas las direcciones del modelo. Es la contracara concreta de por qué el diseño de experimentos (excitación persistente, amplitud de estímulo) importa tanto en identificación [1, 2]. El análisis FIM/SVD sobre el óptimo *real* —no ya sintético— es por lo tanto parte central del entregable, y se espera que *muestre y explique* la baja identificabilidad de varios parámetros.

8. Estado y próximos pasos

Hecho y validado:

- Conversión y verificación del `.mat`; datasets `data8_fs{250,125}.npz`.
- Diagnóstico espectral + coherencia $u \rightarrow s$.
- Baseline ARX (predicción y simulación) y el hallazgo predicción-vs-simulación.
- Trainer por salida (`train_real_output.py`) con multiple shooting y estado latente.
- WC identificable a horizonte corto ($R^2 \approx 0.85$); *rollout* libre cerca del techo ~ 0.1 .

Abierto:

1. **Reencuadrar el trainer al marco de predicción a k pasos** (*prediction-error*): optimizar predicciones de horizonte corto y reportar R^2 vs. horizonte (la curva que va de *teacher-forcing* a simulación) como métrica principal.
2. **Inicialización principista**: anclar la WC linealizada a los **polos del ARX orden-2** $\Rightarrow$ arranque bien condicionado.
3. **Protocolo A completo** (leave-one-out en modo predicción, 3 folds) con barras de parámetros y su dispersión.
4. **V1 (gray-box)**: ver si la corrección g_ϕ captura parte de la dinámica intrínseca que u no explica, cuidando que *no "tape"* al WC (que la parte WC siga interpretable). Como s no está gobernada por u , g_ϕ sin entrada no puede inventar la estocástica; su rol es corregir la estructura, no predecir el ruido.
5. **FIM/SVD** sobre el óptimo real $\Rightarrow$ identificabilidad e incertidumbre (Cramér–Rao).

Observación 2 (La moraleja). *El entregable más valioso de esta tanda no es un R^2 sino un diagnóstico: aprendimos que el estímulo disponible es un driver débil, que la identificación debe hacerse en modo predicción, y que el techo del rollout libre es una propiedad del experimento. Un resultado negativo bien caracterizado vale más que un ajuste optimista mal entendido.*

Referencias

- [1] L. Ljung, *System Identification: Theory for the User*, 2ª ed., Prentice Hall, 1999.

- [2] A. Raue et al., “Structural and practical identifiability analysis of partially observed dynamical models by exploiting the profile likelihood”, *Bioinformatics* 25(15):1923–1929, 2009.
- [3] H. R. Wilson y J. D. Cowan, “Excitatory and inhibitory interactions in localized populations of model neurons”, *Biophysical Journal* 12(1):1–24, 1972.