

R3 — Conclusiones, novedad y trabajo futuro

Qué logramos, qué es aporte propio y qué queda abierto

Proyecto Wilson–Cowan — Iniciación a la I+D ITBA

12 de julio de 2026

Índice

1. Síntesis del proyecto en una página	1
2. Novedad: encuadre honesto	2
3. Qué se puede afirmar vs. qué queda abierto	2
4. Conclusiones por eje	3
5. Trabajo futuro	5

1. Síntesis del proyecto en una página

Este documento cierra el paquete: recoge lo que se hizo, separa lo prestado de lo propio y ordena lo que queda pendiente. Para los números y las figuras de fondo, remitimos a **R1** (resultados de identificación sintética) y a **R2** (datos reales); para el andamiaje conceptual, a **M5** (identificabilidad: Fisher + SVD), **M6** (diseño de estímulo / OED) y **B5** (control en lazo cerrado).

El proyecto se resume en cuatro verbos encadenados sobre el modelo de Wilson–Cowan (WC) [1]:

Identificar.

Recuperar los **10 parámetros** de WC ($w_{EE}, w_{EI}, w_{IE}, w_{II}, \tau_e, \tau_i, a_e, a_i, \theta_e, \theta_i$) a partir de trayectorias sintéticas con ruido, usando una *Neural ODE* como identificador *gray-box* [2, 3]. El arranque es “ignorante”: no se le da a la red el valor verdadero de ningún parámetro. No identificamos solo los 4 pesos de conexión, sino los 10 escalares.

Diagnosticar.

Antes de confiar en los estimados, preguntar *cuáles son recuperables*. La matriz de información de Fisher (FIM) y su descomposición en valores singulares (SVD) responden esto sin siquiera entrenar: la dirección singular más débil apunta casi por completo a w_{II} (autoinhibición). Es el **cuello de botella**: predicho por la geometría de la FIM y *confirmado* después por el barrido de ruido (error $\approx 41\%$ a $\sigma = 0,10$). Ver R1 y M5.

Mitigar.

Tres palancas, todas con método publicado detrás: *subset selection* (fijar el parámetro plano en su prior), *regularización* (penalizar la dirección débil en vez de fijarla) y *diseño de estímulo* (OED: elegir qué inyectar para que la FIM “vea” mejor a w_{II}). Ver R1 y M6.

Validar orientado al control.

El desenlace: el modelo identificado alimenta un controlador IMC en lazo cerrado y se mide, *end-to-end*, si la fragilidad de w_{II} contamina el seguimiento. **No lo hace**: la acción integral del IMC absorbe el error aun con w_{II} mal recuperado. Ver B5.

La moraleja del proyecto en una frase: *la identificabilidad de WC es estructural (hay una dirección intrínsecamente plana, w_{II}), pero esa fragilidad se queda en la identificación y no se propaga al objetivo final, que es controlar el régimen theta-gamma con estímulos realizables por optogenética.*

2. Novedad: encuadre honesto

La regla que seguimos para no inflar la contribución es una plantilla explícita:

“Usa métodos de X (de tal referencia) aplicados a Y con Z (el cambio/hallazgo propio)”.

Es decir: los **métodos son prestados y citados**; el **aporte** es la *combinación* de todos ellos sobre un mismo modelo, más el *hallazgo* concreto (w_{II}) y la observación de que la *fragilidad no llega al control*. Desglosado por eje:

- **Identificabilidad.** Métodos de *Fisher + SVD*, *subset selection* y *profile likelihood* — Golub & Van Loan [8] (la maquinaria SVD/QR), Chu & Hahn [5] (selección de subconjunto de parámetros sobre la matriz de sensibilidad) y Raue et al. [4] (profile likelihood, el estándar de identificabilidad práctica) — *aplicados a WC* identificado con Neural ODE, *con* el hallazgo de que w_{II} es el cuello de botella, predicho sin entrenar y confirmado bajo ruido.
- **Diseño de estímulo.** Métodos de *OED / excitación persistente* — Ljung [6] (identificación de sistemas, entrada persistentemente excitante) y Plate et al. [7] (OED para UDEs con Fisher) — *aplicados a WC*, *con* la ponderación explícita del criterio hacia el cuello de botella (la curva en V del OED ponderado, óptimo en $\rho = 0,5$; ver M6 y R1).
- **Modelado.** *Neural ODE gray-box / UDE* — Chen et al. [2] (Neural ODE) y Rackauckas et al. [3] (universal differential equations) — *aplicado a los 10 parámetros* de WC (no solo los 4 pesos), *con* el arranque ignorante y la validación orientada al control.

Aporte global. La **combinación** de estas piezas sobre un mismo modelo, más el **hallazgo** (w_{II}), más el resultado de que la **fragilidad no se propaga al control**. Formulado con cautela: *hasta donde vimos, es el primer trabajo que identifica los 10 parámetros de Wilson-Cowan con una Neural ODE, diagnostica con Fisher+SVD qué se recupera (w_{II} el límite) y demuestra que esa fragilidad no llega al control en lazo cerrado.*

El antecedente más cercano a diferenciar. *Adaptive Stimulus Design for Dynamic Recurrent Neural Network Models* (PMC6349832) ya muestra que estímulos diseñados óptimamente recuperan mejor las constantes de tiempo y los pesos de conexión de un modelo neuronal. **No nos invalida**, pero hay que nombrarlo con honestidad: (i) el modelo es un RNN dinámico, *no* Wilson-Cowan; (ii) *no cierra el lazo de control*. Nuestro diferencial es precisamente el modelo WC específico y la validación *end-to-end* sobre el controlador.

Observación 1. *Toda afirmación de novedad descansa en una búsqueda acotada (pocas queries, sin bases pagas). Para afirmarla en serio hace falta una búsqueda sistemática (Scholar + arXiv + IEEE Xplore) y, sobre todo, contrastar con el tutor, que conoce su línea mejor que cualquier búsqueda automática.*

3. Qué se puede afirmar vs. qué queda abierto

La honestidad científica exige separar la conclusión firme del *caveat*.

Se puede afirmar (evidencia dentro del setup).

- Con datos sintéticos limpios y multiple shooting, los 10 parámetros de WC se identifican bien desde arranque ignorante (ver R1, ajuste sobre trayectoria de test tipo chirp).
- w_{II} es la dirección estructuralmente débil: la SVD de la FIM lo predice *sin entrenar* y el barrido de ruido lo confirma como el peor parámetro. Es una predicción que se cumple, no una observación aislada.
- El error de identificación de w_{II} **no se propaga** al seguimiento en lazo cerrado dentro del régimen y del controlador IMC probados (ver B5).

Queda abierto (caveats explícitos).

- **Semillas redundantes en el OED ponderado.** La corrida del OED ponderado usó pocas semillas ($5 \rho \times 3$ seeds); parte de la variación entre semillas es redundante y no permite poner barras de error confiables sobre el óptimo $\rho = 0,5$. La forma en V es sugerente, no concluyente.
- **Familia de estímulo y paso dt no concluyentes.** El barrido por familia con dt grande ($\approx 0,2$) mezcla el efecto de la familia con el del error de integración; con dt grueso no se puede separar limpiamente qué estímulo ayuda más ni cuánto pesa el discretizado (ver R1, familia + límite de dt).
- **Datos reales con input débil.** En datos que no son WC puro, la señal de entrada es débil y el modelo de observación (LFP) no está cerrado; los resultados de R2 son exploratorios, no una identificación validada.

4. Conclusiones por eje

Modelo / simulador. El simulador de WC (forma canónica con offsets k_e, k_i derivados para que el reposo sea equilibrio; salida $y = E - I$) es sólido y reproduce el ciclo límite objetivo. Sirve tanto de generador de datos sintéticos como de planta para el control. Es la base común de todo el paquete.

Identificación sintética. La Neural ODE gray-box identifica los 10 parámetros desde arranque ignorante con datos limpios. El pipeline (multiple shooting, reparametrización softplus para positividad, integrador RK4 diferenciable) funciona y converge. Es la prueba de concepto que habilita todo lo demás.

Identificabilidad. El resultado conceptual más limpio del proyecto: existe una dirección plana estructural en el espacio de parámetros, dominada por w_{II} . La Figura 1 lo ilustra: la FIM tiene un valle casi plano a lo largo del cual el costo apenas cambia, y ese valle se alinea con w_{II} . Se predijo con Fisher+SVD y se confirmó con ruido. Las palancas de mitigación (fijar, regularizar, rediseñar el estímulo) atacan exactamente esa dirección.




Figura 1: El “valle plano” de la FIM: a lo largo de la dirección singular más débil el costo casi no cambia, y esa dirección apunta a w_{II} . Por eso w_{II} es el parámetro difícil de identificar. (figura del proyecto)

Control. El desenlace que da sentido al proyecto: la fragilidad de la identificación **no se propaga**. La Figura 2 compara el seguimiento en lazo cerrado usando los parámetros estimados $\hat{\theta}$ frente a los verdaderos; las trayectorias son prácticamente indistinguibles. La acción integral del IMC compensa el error de modelo, incluso con w_{II} mal recuperado. La identificabilidad imperfecta no es un impedimento para el objetivo de control.




Figura 2: Control en lazo cerrado: seguimiento con los parámetros estimados $\hat{\theta}$ vs. los reales. La fragilidad de identificar w_{II} no contamina el seguimiento. (figura del proyecto)

Datos reales. Es el frente menos maduro. Con datos que no son WC puro, el input es débil y falta un modelo de observación (LFP) cerrado. Lo de R2 es una exploración honesta, no una identificación validada; deja el camino marcado para el trabajo futuro.

5. Trabajo futuro

Cinco direcciones, ordenadas de más concreta a más ambiciosa:

1. **OED ponderado realizable.** Repetir la curva en V con estímulos *conmutados* (on/off, ≥ 0), como los que permite la optogenética, con dt fino (para separar el efecto del estímulo del error de integración) y varias realizaciones de ruido para poner **barras de error** sobre el óptimo $\rho = 0,5$. Cierra el caveat de las semillas redundantes.
2. **Gray-box real + modelo de observación LFP.** Activar el término de corrección aprendible (`use_correction=True`) para capturar dinámica que WC puro no modela, y agregar un modelo de observación (LFP) que conecte el estado (E, I) con la señal medida. Es el paso necesario para datos que no son WC puro.
3. **Cerrar PINN vs. Neural ODE bajo ruido.** Completar la comparación entre PINN y Neural ODE en el régimen de ruido, lo que requiere extender la PINN a los 10 parámetros (hoy está en los 4 pesos). Resuelve una comparación que quedó a medias.
4. **Reencuadrar los datos reales como predicción a k pasos.** En vez de exigir identificación de parámetros con input débil, plantear el problema como predicción a k pasos, y luego calcular FIM/SVD sobre el óptimo real encontrado, para diagnosticar qué es identificable *en esos datos concretos* antes de forzar valores.

Estas direcciones alimentan el plan de trabajo del proyecto y refuerzan la contribución sin cambiar el encuadre honesto: seguir usando métodos prestados y citados, y sumar valor en la aplicación, el hallazgo y la validación.

Referencias

- [1] H. R. Wilson y J. D. Cowan, “Excitatory and inhibitory interactions in localized populations of model neurons”, *Biophysical Journal* 12(1):1–24, 1972.
- [2] R. T. Q. Chen, Y. Rubanova, J. Bettencourt y D. Duvenaud, “Neural Ordinary Differential Equations”, *NeurIPS*, 2018.
- [3] C. Rackauckas et al., “Universal Differential Equations for Scientific Machine Learning”, arXiv:2001.04385, 2020.
- [4] A. Raue et al., “Structural and practical identifiability analysis of partially observed dynamical models by exploiting the profile likelihood”, *Bioinformatics* 25(15):1923–1929, 2009.
- [5] Y. Chu y J. Hahn, “Parameter set selection for estimation of nonlinear dynamic systems”, *AIChE Journal* 53(11):2858–2870, 2007.
- [6] L. Ljung, *System Identification: Theory for the User*, 2^a ed., Prentice Hall, 1999.
- [7] C. Plate et al., “Optimal experimental design for universal differential equations”, 2024.
- [8] G. H. Golub y C. F. Van Loan, *Matrix Computations*, 4^a ed., Johns Hopkins University Press, 2013.