

Resultados del escalado progresivo (etapas 0-2)

Qué se probó, qué dio y qué se decidió. Plan en docs/plan_escalado_progresivo.md , proceso paso a paso en docs/bitacora_escalado.md , números en results/escalado/*.json .

Objetivo rector: copiar la dinámica del simulador (NRMSE de rollout open-loop de 200 ms sobre 7 estímulos de test que el modelo nunca vio). Métricas secundarias: R^2 de la corrección contra el Δf verdadero (¿aprendió la física?) y error de parámetros.

Cómo leer las etiquetas de las corridas (e<etapa>_<variante>[_w<ventana>]):

etiqueta	qué modelo es
wb	white-box: Wilson-Cowan puro, sin corrección. Solo ajusta los 10 parámetros.
B	gray-box ciego: WC + red neuronal aditiva $g(I,E)$ que solo ve el estado.
S	estructural: WC + la forma física exacta de la refractariedad, $(1-r \cdot x) \cdot S(u)$, con r aprendible (no hay red). S_2 = misma cosa con r inicial 0.05 y parámetros WC arrancando desde el white-box.
lag	lag estructural: WC + estado del actuador $d\hat{P}/dt=(P-\hat{P})/\tau^{\wedge}$ con $\tau^{\wedge}$ y saturación aprendibles. lag_2 = misma cosa con el estado inicial de cada ventana computado exacto.
lat	latente: WC + estados ocultos genéricos z con dinámica aprendida y corrección $g(I,E,z)$.
_w100/200/400	ventana de multiple shooting en pasos (100 = 5 ms, 200 = 10 ms, 400 = 20 ms).

Resumen ejecutivo

Se volvió a hacer el gray-box de a una perturbación por vez, en lugar de las dos juntas. Resultado: **las dos perturbaciones se copian a ~2-3% de NRMSE por separado**, cuando con las dos juntas el mejor modelo daba 13.1%.

etapa	planta	mejor modelo	NRMSE test	R^2 física	err. param
0	WC puro (piso)	white-box	2.04%	—	1.05%
1	+ refractariedad	estructural + warm-start (e1_S2)	1.70%	0.96	2.4%
1	+ refractariedad	gray-box ciego $g(I,E)$ (e1_B_w400)	2.84%	-0.49	25.6%
2	+ actuador (retardo+sat)	lag estructural, estado exacto (e2_lag2)	2.96%	0.94	5.1%
ref.	las dos juntas (trabajo previo)	gray-box D	13.1%	≈ 0	31%

Las tres cosas que dice esta tabla:

1. **Cuando la corrección tiene la forma correcta y arranca bien, clava la física:** $r = 0.102$ (real 0.10) y $\tau = 0.984$ (real 1.0). Y de paso deja los parámetros WC casi intactos (2-5% de error, contra 31-60% antes).
2. **La corrección ciega $g(I,E)$ copia la dinámica sin entenderla** (2.84%, $R^2 \approx 0$): tapa la refractariedad deformando parámetros. Sirve para predecir, no para cancelar en lazo cerrado.
3. **Los fracasos fueron de optimización, no de modelo.** Las dos correcciones estructurales fallaron primero (colapsaron a WC puro / τ a la mitad) por arrancar en el borde muerto de un `clamp` y por un transitorio falso en multiple shooting. Arregladas las dos cosas, funcionan.

Etapas 0 — el piso

White-box entrenado sobre planta limpia, evaluado con el pipeline nuevo: **2.04%**. Todos los escenarios < 1% salvo `box_a1.2` (10.8%), el escalón grande sostenido — es el caso duro en todas las etapas y hay que leerlo aparte.

Etapas 1 — solo refractariedad

Planta = $WC + (1 - r \cdot x) \cdot S(u)$, $r = 0.10$. Es física **sin memoria**: una función pura de (I,E) , capturable en principio (techo R^2 0.97).

tag	modelo	ventana	NRMSE	R^2	err. param
<code>e1_wb</code>	white-box	5 ms	5.93%	-0.27	11.5%
<code>e1_S</code>	estructural, arranque $r \approx 0$	5 ms	5.92%	-0.27	11.5%
<code>e1_B_w100</code>	gray-box $g(I,E)$	5 ms	2.99%	0.02	21.3%
<code>e1_B_w200</code>	gray-box $g(I,E)$	10 ms	3.31%	-0.39	24.6%
<code>e1_B_w400</code>	gray-box $g(I,E)$	20 ms	2.84%	-0.49	25.6%
<code>e1_S2</code>	estructural, warm-start + $r_0=0.05$	5 ms	1.70%	0.964	2.4%

Qué se aprendió:

- La refractariedad sola es benigna: el white-box la compensa a 5.9% con poca deformación (11.5%). El daño del trabajo previo (14%) venía casi todo del actuador.
- **La ventana de entrenamiento no importa** (2.84-3.31%, dentro del ruido). La hipótesis del plan —que entrenar con 5 ms era el cuello de botella— **no se confirmó**.
- El gray-box ciego recupera el 75% del hueco (5.93 → 2.9%, piso 2.04%) pero con $R^2 \approx 0$: la red y los parámetros se reparten el trabajo de forma arbitraria (la ambigüedad θ/g de F4b). Copia bien, no entiende.
- La estructural con la forma exacta **falló primero** (`e1_S` = white-box: aprendió $r = 0$ exacto). Causa: `r = clamp(raw, 0, 2)` arrancando en 0.01; mientras los θ están lejos el gradiente lo empuja bajo cero y queda pegado al borde sin gradiente. Con warm-start de θ desde el white-box y $r_0 = 0.05$, clava $r_e = 0.102$ y baja a 1.70% — **por debajo del**

piso limpio, porque el piso lo fijaba un white-box con 1% de error de parámetros. r_i quedó en 0: el canal I casi no siente la refractariedad ($|\Delta f_I| \sim 7\times$ menor), no hay señal para moverlo, y no afecta la predicción.

Etapa 2 — solo actuador

Planta = WC con $dP_{\text{lag}}/dt = (P - P_{\text{lag}})/\tau$, $\tau = 1$ ms, y saturación $3 \cdot \tanh(P_{\text{lag}}/3)$. Es física **con memoria**: $g(I, E)$ no puede por diseño.

tag	modelo	NRMSE	R ²	err. param	$\hat{t}$ (real 1.0)
e2_wb	white-box	15.23%	-0.01	30.7%	—
e2_B	gray-box $g(I, E)$ (control negativo)	15.40%	-1.88	34.4%	—
e2_lat_w100	latente $z \in \mathbb{R}^2$ aprendido, 5 ms	14.92%	-0.51	38.9%	—
e2_lat_w400	latente, 20 ms	13.28%	-3.55	52.6%	—
e2_lag	lag estructural, h_0 "asentado"	12.16%	0.65	39.2%	0.56
e2_lag2	lag estructural, h_0 exacto	2.96%	0.942	5.1%	0.984

Qué se aprendió:

- **El actuador solo daña tanto como las dos juntas** (15.2% vs 14.0%): el retardo es el problema real del trabajo previo. Confirma F7.
- $g(I, E)$ no puede (15.4%): control negativo correcto.
- **El latente genérico no ayudó** (13-15%) y arruina los parámetros. Con z arrancando en 0 en cada ventana de 5 ms la memoria no llega a cargarse. No se insistió porque no era el cuello de botella; queda como trabajo futuro (z_0 desde un encoder de la historia, o ventanas con solapamiento).
- La forma física con memoria mejoró de entrada (12.2%, R^2 0.65 — lo único con R^2 positivo hasta ahí) pero **$\hat{t}$ quedó en 0.56, la mitad**. Causa: en multiple shooting cada ventana arrancaba con el filtro "asentado" en el comando ($\hat{P} = P(t_0)$), un salto que la planta no tiene, y el modelo lo minimiza achicando $\hat{t}$. Como el estado del actuador depende **solo del comando (conocido entero) y de $\hat{t}$** , se computa exacto filtrando toda la trayectoria (`LagGrayBox.filtered_inputs`, solución exacta del ZOH, diferenciable en $\hat{t}$). Con eso: **2.96%, $\hat{t} = 0.984$, parámetros al 5%**.
- La **saturación no se identifica** (α cae al borde del clamp aun arrancando en 0.1). Coherente con F1: es $\sim 16\%$ de la deformación del actuador y con $\hat{t}$ bien puesto queda poca señal, que los θ absorben. Es lo que deja `box_a1.2` en 12.8% (donde la saturación sí muerde) mientras el resto queda $< 3\%$.

Las lecciones transversales

1. **De a una perturbación por vez funciona**. El "13%" del trabajo previo no era un techo del gray-box: era la suma de un problema con memoria atacado sin memoria más dos defectos de optimización que las dos perturbaciones juntas ocultaban.
2. **La forma física gana cuando existe, pero hay que inicializarla bien**. Los dos fracasos estructurales tuvieron la misma anatomía: un parámetro físico arrancando en el

borde de un `clamp` (gradiente cero) mientras los θ , aún lejos, se llevan todo el gradiente. Receta que funcionó dos veces: *warm-start* de θ desde el *white-box* + *parámetro físico inicial claramente positivo*.

3. **En multiple shooting, el estado oculto no se supone: se computa.** Si depende de entradas conocidas (como el actuador), filtrarlas entero cuesta nada y elimina un sesgo grande. Si no (latente genérico), hay que darle al modelo una forma de cargarlo — pendiente.
4. **NRMSE bueno $\neq$ física aprendida.** El gray-box ciego llega a 2.8% con $R^2 -0.5$. Para usar el modelo como planta de simulación alcanza; para cancelar en lazo cerrado (F6) no.
5. **La ventana de entrenamiento no fue la perilla.** 5/10/20 ms dan lo mismo. No hace falta seguir barriéndola.

Recomendación para las etapas 3 y 4

Etapla 3 — las dos juntas. Combinar lo que funcionó: backbone WC + término refractario $(1-r \cdot x)$ + estado de actuador con $\hat{t}$, todo aprendible, warm-start desde el white-box, estado inicial exacto por ventana. Número a batir: **13.1%**. Expectativa razonable: 3-4%. Si sale, el "hueco" original queda cerrado con un modelo interpretable y cancelable. Como segunda variante, la misma cosa pero con $g(I, E, z)$ en lugar del término refractario explícito, para medir cuánto cuesta no conocer la forma de la parte sin memoria.

Etapla 4 — full black-box. Sigue teniendo sentido como cota: $\dot{x} = NN(x, P, Q)$ con y sin estados latentes, mismos datos y métricas. Con la referencia de la etapa 2 en mano, la pregunta ya no es "¿el gray-box ayuda?" sino "¿cuánto paga el prior WC frente a una red pura?". Advertencia por el resultado de 2b: la versión con latentes va a necesitar el arreglo de inicialización de z antes de que el número sea justo.

Cosas para no repetir: no más de 2 corridas en paralelo (4 carriles $\times$ 4 hilos en 8 cores multiplicó los tiempos por 50); no barrer más la ventana; guardar `hidden` y demás flags de arquitectura en los checkpoints.

Código: `scripts/esc_gen_datasets.py`, `scripts/esc_run.py`, `scripts/esc_eval.py`,
`src/neural_ode/memory.py`. Checkpoints en `results/escalado/models/`, logs en `logs/escalado/`.